

CONTOH PERHITUNGAN MANUAL STEP-BY-STEP

Gaussian Process Regression (GPR)

Solusi Inversi Langsung ($N = 2$) dan Dekomposisi Cholesky Stabil ($N = 3, N_* = 2$)

Penulis / Mahasiswa: Mahasiswa Tugas Akhir

Fokus Riset: *Image Segmentation with Deep Gaussian Process*

Suplemen Dokumen: Kredit Bimbingan Tugas Akhir #2 (16 September 2026)

16 September 2026

Ringkasan

Dokumen ini merupakan suplemen teknis mandiri yang menyajikan contoh perhitungan manual langkah demi langkah (*worked homework example*) untuk *Gaussian Process Regression* (GPR). Disajikan dua skenario perhitungan: (1) pada dataset berukuran kecil ($N = 2, N_* = 1$) menggunakan metode inversi matriks langsung via rumus adjoin-determinan, dan (2) pada dataset berukuran $N = 3$ dengan $N_* = 2$ titik uji (kasus interpolasi dan ekstrapolasi) menggunakan faktorisasi Cholesky yang stabil secara numerik ($K_y = LL^T$) serta substitusi maju dan mundur. Seluruh tahapan aritmatika diuraikan secara analitik dan eksplisit hingga visualisasi plot hasil serta analisis ketidakpastian epistemik (*epistemic uncertainty*).

Daftar Isi

1	Posterior Formulation Summary	2
2	Direct Inversion ($N = 2, N_* = 1$)	2
3	Cholesky Decomposition ($N = 3, N_* = 2$)	3
3.1	Langkah 1: Konstruksi Matriks Kovariansi Training $K(X, X)$ dan K_y	4
3.2	Langkah 2: Faktorisasi Cholesky $K_y = LL^T$	5
3.3	Langkah 3: Solusi Sistem Linier Dua Tahap untuk Menghitung Vektor Bobot α .	5
3.4	Langkah 4: Evaluasi Kovariansi Titik Test ($K(X_*, X)$ dan $K(X_*, X_*)$)	6
3.5	Langkah 5: Kalkulasi Vektor Mean Prediktif Posterior $\bar{\mathbf{f}}_*$	7
3.6	Langkah 6: Kalkulasi Matriks Kovariansi Prediktif $\text{cov}(\mathbf{f}_*)$	7
3.7	Langkah 7: Visualisasi Plot Hasil & Interpretasi Fisis	8
4	Computational Findings	9

1 Posterior Formulation Summary

Sebagai acuan kerja perhitungan manual, model regresi Gaussian Process dengan galat observasi Gaussian $\epsilon_i \sim \mathcal{N}(0, \sigma_n^2)$ mengasumsikan distribusi bersama antara target observasi $\mathbf{y} \in \mathbb{R}^{N \times 1}$ dan fungsi laten titik uji $\mathbf{f}_* \in \mathbb{R}^{N_* \times 1}$ sebagai Gaussian multivariat (Rasmussen & Williams, 2006, hlm. 16, Persamaan (2.21)):

$$\begin{bmatrix} \mathbf{y} \\ \mathbf{f}_* \end{bmatrix} \sim \mathcal{N} \left(\mathbf{0}, \begin{bmatrix} K(X, X) + \sigma_n^2 I_N & K(X, X_*) \\ K(X_*, X) & K(X_*, X_*) \end{bmatrix} \right) \quad (1)$$

di mana $K_y = K(X, X) + \sigma_n^2 I_N \in \mathbb{R}^{N \times N}$.

Distribusi posterior bersyarat dari nilai fungsi laten $\mathbf{f}_*$ adalah Gaussian (Rasmussen & Williams, 2006, hlm. 17–19, Persamaan (2.22)–(2.24)):

Distribusi Posterior Gaussian Process Regression (Rasmussen & Williams, 2006, hlm. 17–19):

$$\mathbf{f}_* \mid X, \mathbf{y}, X_* \sim \mathcal{N}(\bar{\mathbf{f}}_*, \text{cov}(\mathbf{f}_*)) \quad (2)$$

$$\bar{\mathbf{f}}_* = K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} \mathbf{y} = K(X_*, X) \boldsymbol{\alpha} \in \mathbb{R}^{N_* \times 1} \quad (3)$$

$$\text{cov}(\mathbf{f}_*) = K(X_*, X_*) - K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} K(X, X_*) \in \mathbb{R}^{N_* \times N_*} \quad (4)$$

dengan vektor bobot dual $\boldsymbol{\alpha} = K_y^{-1} \mathbf{y} \in \mathbb{R}^{N \times 1}$.

2 Direct Inversion ($N = 2, N_* = 1$)

Kasus: Diberikan $N = 2$ data training satu dimensi ($D = 1$):

$$\mathcal{D} = \{(x_1 = 0.0, y_1 = 0.00), (x_2 = 1.0, y_2 = 0.84)\}$$

Parameter kernel RBF: $\sigma_f^2 = 1.0$, $l = 1.0$, dan variansi galat $\sigma_n^2 = 0.01$. Rumus kernel:

$$k(x, x') = \exp \left(-\frac{(x - x')^2}{2} \right)$$

Tujuan: Hitung mean prediktif $\bar{f}_*$ dan variansi $\mathbb{V}[f_*]$ pada titik uji tunggal $x_* = 0.5$ menggunakan **inversi matriks langsung** tanpa dekomposisi.

Langkah 1: Bentuk Matriks Kovariansi $K_y \in \mathbb{R}^{2 \times 2}$:

$$k(x_1, x_1) = k(x_2, x_2) = \exp(0) = 1.0000$$

$$k(x_1, x_2) = k(x_2, x_1) = \exp \left(-\frac{(1.0 - 0.0)^2}{2} \right) = e^{-0.5} \approx 0.6065$$

Menambahkan variansi galat $\sigma_n^2 = 0.01$ pada diagonal utama:

$$K_y = \begin{bmatrix} 1.0000 & 0.6065 \\ 0.6065 & 1.0000 \end{bmatrix} + \begin{bmatrix} 0.01 & 0 \\ 0 & 0.01 \end{bmatrix} = \begin{bmatrix} 1.0100 & 0.6065 \\ 0.6065 & 1.0100 \end{bmatrix} \quad (5)$$

Langkah 2: Inversi Matriks Langsung via Rumus Adjoin-Determinan: Determinan dari K_y :

$$\det(K_y) = (1.0100)(1.0100) - (0.6065)(0.6065) = 1.0201 - 0.3678 = 0.6523 \quad (6)$$

Invers dari matriks 2×2 langsung dihitung:

$$K_y^{-1} = \frac{1}{\det(K_y)} \begin{bmatrix} [K_y]_{22} & -[K_y]_{12} \\ -[K_y]_{21} & [K_y]_{11} \end{bmatrix} = \frac{1}{0.6523} \begin{bmatrix} 1.0100 & -0.6065 \\ -0.6065 & 1.0100 \end{bmatrix} \approx \begin{bmatrix} 1.5484 & -0.9298 \\ -0.9298 & 1.5484 \end{bmatrix} \quad (7)$$

Langkah 3: Hitung Vektor Bobot $\alpha = K_y^{-1}\mathbf{y}$: Dengan vektor target $\mathbf{y} = [0.00, 0.84]^T$:

$$\alpha = \begin{bmatrix} 1.5484 & -0.9298 \\ -0.9298 & 1.5484 \end{bmatrix} \begin{bmatrix} 0.00 \\ 0.84 \end{bmatrix} = \begin{bmatrix} (-0.9298)(0.84) \\ (1.5484)(0.84) \end{bmatrix} \approx \begin{bmatrix} -0.7810 \\ 1.3007 \end{bmatrix} \quad (8)$$

Langkah 4: Evaluasi Kovariansi Titik Uji $x_* = 0.5$:

$$\mathbf{k}_* = \begin{bmatrix} k(x_1, x_*) \\ k(x_2, x_*) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(0.0-0.5)^2}{2}\right) \\ \exp\left(-\frac{(1.0-0.5)^2}{2}\right) \end{bmatrix} = \begin{bmatrix} e^{-0.125} \\ e^{-0.125} \end{bmatrix} \approx \begin{bmatrix} 0.8825 \\ 0.8825 \end{bmatrix}$$

$$k_{**} = k(x_*, x_*) = \exp(0) = 1.0000$$

Langkah 5: Hitung Mean dan Variansi Prediktif Posterior: Mean prediktif:

$$\bar{f}_* = \mathbf{k}_*^T \alpha = \begin{bmatrix} 0.8825 & 0.8825 \end{bmatrix} \begin{bmatrix} -0.7810 \\ 1.3007 \end{bmatrix} = (0.8825)(-0.7810 + 1.3007) = (0.8825)(0.5197) \approx \mathbf{0.4586} \quad (9)$$

Variansi prediktif:

$$\begin{aligned} \mathbb{V}[f_*] &= k_{**} - \mathbf{k}_*^T K_y^{-1} \mathbf{k}_* \\ &= 1.0000 - \begin{bmatrix} 0.8825 & 0.8825 \end{bmatrix} \begin{bmatrix} 1.5484 & -0.9298 \\ -0.9298 & 1.5484 \end{bmatrix} \begin{bmatrix} 0.8825 \\ 0.8825 \end{bmatrix} \\ &= 1.0000 - \begin{bmatrix} 0.8825 & 0.8825 \end{bmatrix} \begin{bmatrix} 0.5459 \\ 0.5459 \end{bmatrix} = 1.0000 - 2(0.8825)(0.5459) \\ &= 1.0000 - 0.9635 = \mathbf{0.0365} \implies \sigma_* = \sqrt{0.0365} \approx \mathbf{0.1910} \end{aligned} \quad (10)$$

Terlihat bahwa untuk $N = 2$, perhitungan di atas kertas sangat ringkas dan praktis diselesaikan secara langsung tanpa perlu melakukan faktorisasi segitiga.

3 Cholesky Decomposition ($N = 3, N_* = 2$)

Motivasi Penggunaan Dekomposisi Cholesky: Ketika ukuran data bertambah ($N \geq 3$), mencari invers matriks K_y^{-1} secara langsung di atas kertas menjadi sangat sulit dan tidak efisien karena menuntut kalkulasi N^2 kofaktor determinan minor satu per satu yang rawan salah tanda kurung dan aljabar. Selain itu, pada implementasi komputer, matriks kernel sering kali memiliki bilangan kondisi tinggi (*ill-conditioned*), sehingga inversi langsung memicu ledakan galat pembulatan. Oleh karena itu, kita memfaktorkan matriks simetris positif definit K_y menjadi **Faktorisasi Cholesky** (Rasmussen & Williams, 2006, hlm. 19, Algoritma 2.1):

$$K_y = LL^T \quad (11)$$

di mana L adalah matriks segitiga bawah riil (*lower triangular*) dengan diagonal positif.

Strategi Substitusi yang Digunakan: Dengan faktorisasi $K_y = LL^T$, kita tidak perlu menghitung matriks K_y^{-1} sama sekali (Rasmussen & Williams, 2006, hlm. 19, Baris 2–6 Algoritma 2.1):

1. **Vektor Bobot α (Mean Posterior):** Diselesaikan via sistem rantai dua tahap:

- *Forward substitution:* Pecahkan $L\mathbf{v} = \mathbf{y}$ untuk memperoleh vektor perantara $\mathbf{v} = L^{-1}\mathbf{y}$.
- *Backward substitution:* Pecahkan $L^T\alpha = \mathbf{v}$ untuk memperoleh vektor bobot $\alpha = L^{-T}\mathbf{v} = K_y^{-1}\mathbf{y}$.

Mean prediktif kemudian dihitung melalui $\bar{\mathbf{f}}_* = K(X_*, X)\alpha$.

2. **Matriks Kovariansi Posterior:** Suku pengurang $\Omega = K(X_*, X)K_y^{-1}K(X, X_*)$ ditransformasikan menjadi bentuk kuadratik $\Omega = W^TW$, di mana matriks $W \in \mathbb{R}^{N \times N_*}$ diselesaikan kolom demi kolom via substitusi maju $L\mathbf{w}_j = K(X, \mathbf{x}_{*j})$ untuk setiap test point $j \in \{1, \dots, N_*\}$.

Deskripsi Masalah Tugas (*Homework Assignment*):

Diberikan training dataset $N = 3$ dengan dimensi input tunggal $D = 1$:

$$\mathcal{D} = \{(x_1 = 0.0, y_1 = 0.00), (x_2 = 1.0, y_2 = 0.84), (x_3 = 2.0, y_3 = 0.91)\}$$

Model diasumsikan menggunakan fungsi kernel RBF dengan parameter kernel dan variansi galat yang telah ditetapkan:

$$\sigma_f^2 = 1.0, \quad l = 1.0, \quad \sigma_n^2 = 0.01 \implies k(x, x') = \exp\left(-\frac{(x - x')^2}{2}\right)$$

Tugas: Hitunglah distribusi posterior prediktif (vektor mean $\bar{\mathbf{f}}_*$ dan matriks kovariansi $\text{cov}(\mathbf{f}_*)$) pada $N_* = 2$ test point:

$$x_{*1} = 0.5 \quad (\text{Kasus Interpolasi}), \quad x_{*2} = 2.5 \quad (\text{Kasus Ekstrapolasi})$$

menggunakan **Faktorisasi Cholesky** $K_y = LL^T$ dan substitusi maju/mundur.

3.1 Langkah 1: Konstruksi Matriks Kovariansi Training $K(X, X)$ dan K_y

Matriks desain training data adalah:

$$X = \begin{bmatrix} 0.0 \\ 1.0 \\ 2.0 \end{bmatrix} \in \mathbb{R}^{3 \times 1}, \quad \mathbf{y} = \begin{bmatrix} 0.00 \\ 0.84 \\ 0.91 \end{bmatrix} \in \mathbb{R}^{3 \times 1} \quad (12)$$

Evaluasi pasangan kernel:

$$\begin{aligned} k(x_1, x_1) &= k(x_2, x_2) = k(x_3, x_3) = \exp(0) = 1.0000 \\ k(x_1, x_2) &= k(x_2, x_3) = \exp\left(-\frac{(1.0 - 0.0)^2}{2}\right) = e^{-0.5} \approx 0.6065 \\ k(x_1, x_3) &= \exp\left(-\frac{(2.0 - 0.0)^2}{2}\right) = e^{-2.0} \approx 0.1353 \end{aligned}$$

Menyusun matriks Gram $K(X, X) \in \mathbb{R}^{3 \times 3}$:

$$K(X, X) = \begin{bmatrix} 1.0000 & 0.6065 & 0.1353 \\ 0.6065 & 1.0000 & 0.6065 \\ 0.1353 & 0.6065 & 1.0000 \end{bmatrix} \quad (13)$$

Menambahkan variansi galat $\sigma_n^2 I_3 = 0.01 I_3$ untuk memperoleh matriks kovariansi observasi total $K_y \in \mathbb{R}^{3 \times 3}$:

$$K_y = K(X, X) + 0.01 I_3 = \begin{bmatrix} 1.0100 & 0.6065 & 0.1353 \\ 0.6065 & 1.0100 & 0.6065 \\ 0.1353 & 0.6065 & 1.0100 \end{bmatrix} \quad (14)$$

3.2 Langkah 2: Faktorisasi Cholesky $K_y = LL^T$

Kita mencari matriks segitiga bawah $L \in \mathbb{R}^{3 \times 3}$ sedemikian sehingga $K_y = LL^T$:

$$\begin{bmatrix} 1.0100 & 0.6065 & 0.1353 \\ 0.6065 & 1.0100 & 0.6065 \\ 0.1353 & 0.6065 & 1.0100 \end{bmatrix} = \begin{bmatrix} L_{11} & 0 & 0 \\ L_{21} & L_{22} & 0 \\ L_{31} & L_{32} & L_{33} \end{bmatrix} \begin{bmatrix} L_{11} & L_{21} & L_{31} \\ 0 & L_{22} & L_{32} \\ 0 & 0 & L_{33} \end{bmatrix} \quad (15)$$

Perhitungan Kolom 1:

$$\begin{aligned} L_{11} &= \sqrt{[K_y]_{11}} = \sqrt{1.0100} \approx \mathbf{1.0050} \\ L_{21} &= \frac{[K_y]_{21}}{L_{11}} = \frac{0.6065}{1.0050} \approx \mathbf{0.6035} \\ L_{31} &= \frac{[K_y]_{31}}{L_{11}} = \frac{0.1353}{1.0050} \approx \mathbf{0.1346} \end{aligned}$$

Perhitungan Kolom 2:

$$\begin{aligned} L_{22} &= \sqrt{[K_y]_{22} - L_{21}^2} = \sqrt{1.0100 - (0.6035)^2} = \sqrt{1.0100 - 0.3642} = \sqrt{0.6458} \approx \mathbf{0.8036} \\ L_{32} &= \frac{[K_y]_{32} - L_{31}L_{21}}{L_{22}} = \frac{0.6065 - (0.1346)(0.6035)}{0.8036} = \frac{0.6065 - 0.0812}{0.8036} = \frac{0.5253}{0.8036} \approx \mathbf{0.6537} \end{aligned}$$

Perhitungan Kolom 3:

$$\begin{aligned} L_{33} &= \sqrt{[K_y]_{33} - L_{31}^2 - L_{32}^2} = \sqrt{1.0100 - (0.1346)^2 - (0.6537)^2} \\ &= \sqrt{1.0100 - 0.0181 - 0.4273} = \sqrt{0.5646} \approx \mathbf{0.7514} \end{aligned}$$

Dengan demikian, matriks faktor Cholesky L adalah:

$$L = \begin{bmatrix} 1.0050 & 0 & 0 \\ 0.6035 & 0.8036 & 0 \\ 0.1346 & 0.6537 & 0.7514 \end{bmatrix} \in \mathbb{R}^{3 \times 3} \quad (16)$$

3.3 Langkah 3: Solusi Sistem Linier Dua Tahap untuk Menghitung Vektor Bobot α

Kita ingin mencari $\alpha = K_y^{-1} \mathbf{y}$ dengan menyelesaikan $LL^T \alpha = \mathbf{y}$.

Tahap 1: Forward Substitution ($L\mathbf{v} = \mathbf{y}$)

$$\begin{bmatrix} 1.0050 & 0 & 0 \\ 0.6035 & 0.8036 & 0 \\ 0.1346 & 0.6537 & 0.7514 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} 0.00 \\ 0.84 \\ 0.91 \end{bmatrix} \quad (17)$$

$$v_1 = \frac{0.00}{1.0050} = \mathbf{0.0000}$$

$$v_2 = \frac{0.84 - (0.6035)(v_1)}{0.8036} = \frac{0.84 - 0}{0.8036} \approx \mathbf{1.0453}$$

$$v_3 = \frac{0.91 - (0.1346)(v_1) - (0.6537)(v_2)}{0.7514} = \frac{0.91 - 0 - (0.6537)(1.0453)}{0.7514} = \frac{0.91 - 0.6833}{0.7514} \approx \mathbf{0.3017}$$

Diperoleh vektor perantara:

$$\mathbf{v} = \begin{bmatrix} 0.0000 \\ 1.0453 \\ 0.3017 \end{bmatrix} \in \mathbb{R}^{3 \times 1} \quad (18)$$

Tahap 2: Backward Substitution ($L^T \boldsymbol{\alpha} = \mathbf{v}$)

$$\begin{bmatrix} 1.0050 & 0.6035 & 0.1346 \\ 0 & 0.8036 & 0.6537 \\ 0 & 0 & 0.7514 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \begin{bmatrix} 0.0000 \\ 1.0453 \\ 0.3017 \end{bmatrix} \quad (19)$$

$$\alpha_3 = \frac{0.3017}{0.7514} \approx \mathbf{0.4015}$$

$$\alpha_2 = \frac{1.0453 - (0.6537)(\alpha_3)}{0.8036} = \frac{1.0453 - (0.6537)(0.4015)}{0.8036} = \frac{1.0453 - 0.2625}{0.8036} \approx \mathbf{0.9741}$$

$$\begin{aligned} \alpha_1 &= \frac{0.0000 - (0.6035)(\alpha_2) - (0.1346)(\alpha_3)}{1.0050} = \frac{-(0.6035)(0.9741) - (0.1346)(0.4015)}{1.0050} \\ &= \frac{-0.5879 - 0.0540}{1.0050} = \frac{-0.6419}{1.0050} \approx \mathbf{-0.6387} \end{aligned}$$

Diperoleh vektor bobot dual akhir:

$$\boldsymbol{\alpha} = \begin{bmatrix} -0.6387 \\ 0.9741 \\ 0.4015 \end{bmatrix} \in \mathbb{R}^{3 \times 1} \quad (20)$$

3.4 Langkah 4: Evaluasi Kovariansi Titik Test ($K(X_*, X)$ dan $K(X_*, X_*)$)

Diberikan test point $X_* = [0.5, 2.5]^T \in \mathbb{R}^{2 \times 1}$.

Evaluasi Matriks Kovariansi Silang $K(X_*, X) \in \mathbb{R}^{2 \times 3}$:

- Baris 1 ($x_{*1} = 0.5$):

$$k(0.5, 0.0) = \exp\left(-\frac{(0.5)^2}{2}\right) = e^{-0.125} \approx 0.8825$$

$$k(0.5, 1.0) = \exp\left(-\frac{(-0.5)^2}{2}\right) = e^{-0.125} \approx 0.8825$$

$$k(0.5, 2.0) = \exp\left(-\frac{(-1.5)^2}{2}\right) = e^{-1.125} \approx 0.3247$$

- Baris 2 ($x_{*2} = 2.5$):

$$\begin{aligned} k(2.5, 0.0) &= \exp\left(-\frac{(2.5)^2}{2}\right) = e^{-3.125} \approx 0.0439 \\ k(2.5, 1.0) &= \exp\left(-\frac{(1.5)^2}{2}\right) = e^{-1.125} \approx 0.3247 \\ k(2.5, 2.0) &= \exp\left(-\frac{(0.5)^2}{2}\right) = e^{-0.125} \approx 0.8825 \end{aligned}$$

Sehingga:

$$K(X_*, X) = \begin{bmatrix} 0.8825 & 0.8825 & 0.3247 \\ 0.0439 & 0.3247 & 0.8825 \end{bmatrix} \in \mathbb{R}^{2 \times 3} \quad (21)$$

Evaluasi Matriks Prior Antar Titik Test $K(X_*, X_*) \in \mathbb{R}^{2 \times 2}$:

$$\begin{aligned} k(x_{*1}, x_{*1}) &= k(x_{*2}, x_{*2}) = \exp(0) = 1.0000 \\ k(x_{*1}, x_{*2}) &= \exp\left(-\frac{(2.5 - 0.5)^2}{2}\right) = e^{-2.0} \approx 0.1353 \\ K(X_*, X_*) &= \begin{bmatrix} 1.0000 & 0.1353 \\ 0.1353 & 1.0000 \end{bmatrix} \in \mathbb{R}^{2 \times 2} \end{aligned} \quad (22)$$

3.5 Langkah 5: Kalkulasi Vektor Mean Prediktif Posterior $\bar{\mathbf{f}}_*$

Mean prediktif diperoleh dari perkalian matriks:

$$\bar{\mathbf{f}}_* = K(X_*, X)\boldsymbol{\alpha} = \begin{bmatrix} 0.8825 & 0.8825 & 0.3247 \\ 0.0439 & 0.3247 & 0.8825 \end{bmatrix} \begin{bmatrix} -0.6387 \\ 0.9741 \\ 0.4015 \end{bmatrix} \quad (23)$$

$$\begin{aligned} \bar{f}_{*1} &= (0.8825)(-0.6387) + (0.8825)(0.9741) + (0.3247)(0.4015) \\ &= -0.5637 + 0.8596 + 0.1304 = \mathbf{0.4263} \\ \bar{f}_{*2} &= (0.0439)(-0.6387) + (0.3247)(0.9741) + (0.8825)(0.4015) \\ &= -0.0280 + 0.3163 + 0.3543 = \mathbf{0.6426} \end{aligned}$$

Hasil akhir vektor mean prediktif posterior adalah:

$$\bar{\mathbf{f}}_* = \begin{bmatrix} 0.4263 \\ 0.6426 \end{bmatrix} \in \mathbb{R}^{2 \times 1} \quad (24)$$

3.6 Langkah 6: Kalkulasi Matriks Kovariansi Prediktif $\text{cov}(\mathbf{f}_*)$

Berdasarkan Persamaan (4):

$$\text{cov}(\mathbf{f}_*) = K(X_*, X_*) - K(X_*, X)K_y^{-1}K(X, X_*) \quad (25)$$

Dengan mendefinisikan $W = L^{-1}K(X, X_*) \in \mathbb{R}^{3 \times 2}$, maka suku pengurang dapat dihitung melalui $W^T W$. Kita selesaikan $LW = K(X, X_*)$ melalui substitusi maju untuk kedua kolom $\mathbf{w}_1$ dan $\mathbf{w}_2$:

Kolom 1 ($x_{*1} = 0.5$):

$$w_{11} = \frac{0.8825}{1.0050} \approx \mathbf{0.8781}$$

$$w_{21} = \frac{0.8825 - (0.6035)(0.8781)}{0.8036} = \frac{0.8825 - 0.5300}{0.8036} = \frac{0.3525}{0.8036} \approx \mathbf{0.4386}$$

$$w_{31} = \frac{0.3247 - (0.1346)(0.8781) - (0.6537)(0.4386)}{0.7514} = \frac{0.3247 - 0.1182 - 0.2867}{0.7514} = \frac{-0.0802}{0.7514} \approx \mathbf{-0.1067}$$

Kolom 2 ($x_{*2} = 2.5$):

$$w_{12} = \frac{0.0439}{1.0050} \approx \mathbf{0.0437}$$

$$w_{22} = \frac{0.3247 - (0.6035)(0.0437)}{0.8036} = \frac{0.3247 - 0.0264}{0.8036} = \frac{0.2983}{0.8036} \approx \mathbf{0.3712}$$

$$w_{32} = \frac{0.8825 - (0.1346)(0.0437) - (0.6537)(0.3712)}{0.7514} = \frac{0.8825 - 0.0059 - 0.2426}{0.7514} = \frac{0.6340}{0.7514} \approx \mathbf{0.8438}$$

Matriks perantara $W \in \mathbb{R}^{3 \times 2}$ adalah:

$$W = \begin{bmatrix} 0.8781 & 0.0437 \\ 0.4386 & 0.3712 \\ -0.1067 & 0.8438 \end{bmatrix} \quad (26)$$

Menghitung perkalian matriks $W^T W \in \mathbb{R}^{2 \times 2}$:

$$[W^T W]_{11} = (0.8781)^2 + (0.4386)^2 + (-0.1067)^2 = 0.7711 + 0.1924 + 0.0114 = \mathbf{0.9749}$$

$$[W^T W]_{22} = (0.0437)^2 + (0.3712)^2 + (0.8438)^2 = 0.0019 + 0.1378 + 0.7120 = \mathbf{0.8517}$$

$$[W^T W]_{12} = [W^T W]_{21} = (0.8781)(0.0437) + (0.4386)(0.3712) + (-0.1067)(0.8438) \\ = 0.0384 + 0.1628 - 0.0900 = \mathbf{0.1112}$$

Maka matriks kovariansi prediktif posterior adalah:

$$\text{cov}(\mathbf{f}_*) = \begin{bmatrix} 1.0000 & 0.1353 \\ 0.1353 & 1.0000 \end{bmatrix} - \begin{bmatrix} 0.9749 & 0.1112 \\ 0.1112 & 0.8517 \end{bmatrix} = \begin{bmatrix} \mathbf{0.0251} & 0.0241 \\ 0.0241 & \mathbf{0.1483} \end{bmatrix} \in \mathbb{R}^{2 \times 2} \quad (27)$$

3.7 Langkah 7: Visualisasi Plot Hasil & Interpretasi Fisis

Dari hasil matriks kovariansi posterior di atas, kita peroleh variansi individual dan deviasi standar untuk masing-masing test point:

- **Titik Interpolasi** ($x_{*1} = 0.5$):

$$\mathbb{V}[f_{*1}] = [\text{cov}(\mathbf{f}_*)]_{11} = \mathbf{0.0251} \implies \sigma_{*1} = \sqrt{0.0251} \approx \mathbf{0.1584} \quad (28)$$


Karena $x_{*1} = 0.5$ diapit sangat dekat oleh data observasi $x_1 = 0.0$ dan $x_2 = 1.0$, data memberikan reduksi ketidakpastian yang masif, menyusutkan variansi dari prior 1.0000 menjadi hanya 0.0251 (terjadi reduksi ketidakpastian sebesar 97.5%).

- **Titik Ekstrapolasi** ($x_{*2} = 2.5$):

$$\mathbb{V}[f_{*2}] = [\text{cov}(\mathbf{f}_*)]_{22} = \mathbf{0.1483} \implies \sigma_{*2} = \sqrt{0.1483} \approx \mathbf{0.3851} \quad (29)$$

Titik $x_{*2} = 2.5$ berada di luar rentang observasi training samples (data terjauh berada di $x_3 = 2.0$). Oleh karena itu, variansinya hampir $6 \times$ lipat lebih besar dibanding titik interpolasi, secara matematis membuktikan bahwa model mengekspresikan ketidakpastian epistemik yang tinggi di area tanpa observasi.

- **Korelasi Silang Posterior:** Elemen non-diagonal bernilai positif ($[\text{cov}(\mathbf{f}_*)]_{12} = 0.0241 > 0$), menunjukkan bahwa meskipun kedua test point terpisah sejauh $\Delta x = 2.0$, keduanya tetap mempertahankan kovariansi positif yang lemah sesuai kontinuitas fungsi kernel.



Gambar 1: Hasil Eksak Regresi Gaussian Process pada Soal Latihan ($N = 3, N_* = 2$): Menampilkan kurva mean kontinu $\hat{f}(x)$, pita ketidakpastian posterior 95% ($\pm 2\sigma(x)$), serta posisi kedua test point $x_{*1} = 0.5$ dan $x_{*2} = 2.5$.

4 Computational Findings

Dari penurunan manual di atas, kita mengamati dua sifat komputasi krusial:

1. Algoritma Cholesky dua tahap menghindari inversi langsung K_y^{-1} , menjaga kestabilan numerik dan menjamin kompleksitas tetap efisien $\frac{1}{3}N^3$ operasi perkalian-penjumlahan (Rasmussen & Williams, 2006, hlm. 19, Algoritma 2.1).
2. Variansi posterior prediktif terbukti independen dari target observasi $\mathbf{y}$, hanya bergantung pada lokasi masukan X dan X_* serta parameter kernel, sehingga mencerminkan ketidakpastian epistemik murni.

Pustaka

[Rasmussen & Williams(2006)] C. E. Rasmussen and C. K. I. Williams. *Gaussian Processes for Machine Learning*. Adaptive Computation and Machine Learning. MIT Press, Cambridge, MA, USA, 2006. URL: <http://www.gaussianprocess.org/gpml/>.