

BIMBINGAN TUGAS AKHIR #2

16 September 2026

1 Function-Space View & Gaussian Process

Gaussian Process (GP) adalah metode non-parametrik yang bekerja langsung pada *function-space* (Rasmussen & Williams, 2006, Bab 2, hlm. 13–15). Alih-alih mencari nilai parameter atau bobot tertentu, GP langsung memodelkan sebaran probabilitas dari berbagai kemungkinan bentuk fungsi $f(\mathbf{x})$.

Definisi 1.1 (Gaussian Process (Rasmussen & Williams, 2006, Definisi 2.1, hlm. 13)). *Suatu Gaussian Process adalah koleksi variabel acak $\{f(\mathbf{x}) \mid \mathbf{x} \in \mathcal{X}\}$ di mana setiap subset berhingga dari indeks $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ menghasilkan distribusi bersama (joint distribution) multivariat Gaussian.*


Secara matematis, karakteristik Gaussian Process ditentukan oleh dua komponen utama, yaitu sebuah fungsi mean $m(\mathbf{x}) \in \mathbb{R}$ dan sebuah fungsi kovariansi/kernel $k(\mathbf{x}, \mathbf{x}') \in \mathbb{R}$ (Rasmussen & Williams, 2006, hlm. 13, Persamaan (2.13)–(2.14)):

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})], \quad (1)$$

$$k(\mathbf{x}, \mathbf{x}') = \mathbb{E}[(f(\mathbf{x}) - m(\mathbf{x}))(f(\mathbf{x}') - m(\mathbf{x}'))] \quad (2)$$

sehingga proses stokastik ini dinotasikan sebagai:

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \quad (3)$$



Gambar 1: Visualisasi Gaussian Process: (a) Sampel-sampel fungsi prior dari $\mathcal{GP}(0, k(\mathbf{x}, \mathbf{x}'))$ dengan pita ketidakpastian konstan 95%, dan (b) Sampel-sampel fungsi posterior setelah mengamati empat titik training data, memperlihatkan penyempitan pita ketidakpastian di sekitar titik data.

2 Covariance Functions (Kernels)

Fungsi kovariansi $k(\mathbf{x}, \mathbf{x}')$ mengukur tingkat kemiripan antara dua titik input: jika nilai input $\mathbf{x}$ dan $\mathbf{x}'$ berdekatan, maka nilai fungsinya $f(\mathbf{x})$ dan $f(\mathbf{x}')$ juga akan bernilai mirip (berkorelasi tinggi).

2.1 Syarat Kelayakan Kernel (Positive Semi-Definite)

Agar matriks kovariansi $K \in \mathbb{R}^{N \times N}$ merepresentasikan distribusi Gaussian multivariat yang valid, matriks K wajib bersifat simetris dan positif semi-definit (Rasmussen & Williams, 2006, Definisi 4.1, hlm. 82). Artinya, untuk setiap himpunan titik $\{\mathbf{x}_i\}_{i=1}^N$ dan vektor bobot sembarang $\mathbf{v} \in \mathbb{R}^{N \times 1} \setminus \{\mathbf{0}\}$, berlaku:

$$\mathbf{v}^T K \mathbf{v} \geq 0 \quad (4)$$

2.2 Kernel Stasioner (*Stationary Kernels*)

Kernel stasioner adalah fungsi kovariansi yang bersifat invarian terhadap translasi input, yaitu nilainya hanya bergantung pada selisih jarak relatif antara dua titik:

$$r = \|\mathbf{x} - \mathbf{x}'\| \quad (5)$$

2.2.1 Kernel Squared Exponential (RBF / Gaussian)

Kernel *Squared Exponential* (SE) merupakan kernel yang paling umum dipakai, menghasilkan fungsi kontinu yang dapat diturunkan tak hingga kali (*infinitely mean square differentiable*) (Rasmussen & Williams, 2006, hlm. 83, Persamaan (4.9)):

$$k_{\text{SE}}(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2l^2}\right) = \sigma_f^2 \exp\left(-\frac{(\mathbf{x} - \mathbf{x}')^T (\mathbf{x} - \mathbf{x}')}{2l^2}\right) \quad (6)$$

2.2.2 Keluarga Kernel Matérn

Keluarga kernel Matérn memberikan kendali atas derajat diferensiabilitas fungsi sampel (Rasmussen & Williams, 2006, hlm. 84–85, Persamaan (4.14)):

$$k_{\text{Matérn}}(r) = \sigma_f^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\frac{\sqrt{2\nu}r}{l}\right)^\nu K_\nu\left(\frac{\sqrt{2\nu}r}{l}\right) \quad (7)$$

Dua nilai ν yang paling lazim dalam literatur adalah:

- **Matérn $\nu = 3/2$** (Rasmussen & Williams, 2006, hlm. 85, Persamaan (4.17)):

$$k_{\nu=3/2}(r) = \sigma_f^2 \left(1 + \frac{\sqrt{3}r}{l}\right) \exp\left(-\frac{\sqrt{3}r}{l}\right) \quad (8)$$

- **Matérn $\nu = 5/2$** (Rasmussen & Williams, 2006, hlm. 85, Persamaan (4.17)):

$$k_{\nu=5/2}(r) = \sigma_f^2 \left(1 + \frac{\sqrt{5}r}{l} + \frac{5r^2}{3l^2}\right) \exp\left(-\frac{\sqrt{5}r}{l}\right) \quad (9)$$

2.3 Kernel Non-Stasioner (*Non-Stationary Kernels*)

Kernel non-stasioner adalah fungsi kovariansi yang nilainya tidak hanya bergantung pada jarak relatif, melainkan bergantung langsung pada posisi absolut dari input $\mathbf{x}$ dan $\mathbf{x}'$ (Rasmussen & Williams, 2006, hlm. 89–90).

2.3.1 Kernel Linear

Kernel linear bersesuaian dengan regresi linear Bayesian (Rasmussen & Williams, 2006, hlm. 89, Persamaan (4.22)):

$$k(\mathbf{x}, \mathbf{x}') = \sigma_0^2 + \mathbf{x}^T \mathbf{x}' \quad (10)$$

Parameter $\sigma_0^2 \geq 0$ menyatakan variansi dari suku bias/konstanta. Berdasarkan nilai σ_0^2 , kernel linear dibedakan menjadi dua jenis:

- **Homogen (*Homogeneous*)**: Jika $\sigma_0^2 = 0$, fungsi kovariansi murni berupa hasil kali titik $k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}'$. Seluruh fungsi sampel linear yang dihasilkan dipaksa melewati titik pusat/origin ($f(\mathbf{0}) = 0$).
- **Inhomogen (*Inhomogeneous*)**: Jika $\sigma_0^2 > 0$, fungsi sampel berupa garis linear sembarang dengan pergeseran vertikal (*intercept*) acak ($f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$).

Karena nilainya dipengaruhi langsung oleh magnitudo dan posisi absolut $\mathbf{x}$ serta $\mathbf{x}'$ (bukan selisih jarak $\mathbf{x} - \mathbf{x}'$), kernel linear tergolong non-stasioner.

3 Gaussian Process Regression Model

Observasi data target sering kali dipengaruhi oleh galat pengukuran (Rasmussen & Williams, 2006, hlm. 16). Model regresi didefinisikan sebagai:

$$y_i = f(\mathbf{x}_i) + \epsilon_i, \quad i = 1, \dots, N \quad (11)$$

di mana residu galat diasumsikan saling bebas dan berdistribusi identik (*i.i.d.*) Gaussian:

$$\epsilon_i \sim \mathcal{N}(0, \sigma_n^2) \implies \boldsymbol{\epsilon} = [\epsilon_1, \dots, \epsilon_N]^T \sim \mathcal{N}(\mathbf{0}_{N \times 1}, \sigma_n^2 I_N) \quad (12)$$

di mana $\sigma_n^2 \in \mathbb{R}^+$ adalah variansi galat (skalar) dan $I_N \in \mathbb{R}^{N \times N}$ adalah matriks identitas.

Kovariansi antara dua observasi sembarang y_p dan y_q dapat diturunkan langsung dari sifat ekspektasi linearitas:

$$\begin{aligned} \text{cov}(y_p, y_q) &= \mathbb{E}[(y_p - 0)(y_q - 0)] \\ &= \mathbb{E}[(f(\mathbf{x}_p) + \epsilon_p)(f(\mathbf{x}_q) + \epsilon_q)] \\ &= \mathbb{E}[f(\mathbf{x}_p)f(\mathbf{x}_q)] + \mathbb{E}[f(\mathbf{x}_p)\epsilon_q] + \mathbb{E}[\epsilon_p f(\mathbf{x}_q)] + \mathbb{E}[\epsilon_p \epsilon_q] \\ &= k(\mathbf{x}_p, \mathbf{x}_q) + 0 + 0 + \sigma_n^2 \delta_{pq} \end{aligned} \quad (13)$$

di mana δ_{pq} adalah fungsi delta Kronecker ($\delta_{pq} = 1$ jika $p = q$, dan 0 jika $p \neq q$).

Dalam notasi matriks penuh, matriks kovariansi observed training data $K_y \in \mathbb{R}^{N \times N}$ dirumuskan sebagai:

$$K_y = K(X, X) + \sigma_n^2 I_N \in \mathbb{R}^{N \times N} \quad (14)$$

dengan elemen matriks $[K(X, X)]_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$.

4 Posterior Conditioning & Inference

Misalkan diberikan himpunan N_* test input points yang disusun dalam matriks $X_* \in \mathbb{R}^{N_* \times D}$. Tujuan inferensi Bayesian adalah memperoleh distribusi probabilitas bersyarat dari nilai fungsi laten test $\mathbf{f}_* = [f(\mathbf{x}_{*1}), \dots, f(\mathbf{x}_{*N_*})]^T \in \mathbb{R}^{N_* \times 1}$ dengan syarat training data yang diobservasi $(X, \mathbf{y})$, yaitu:


$$p(\mathbf{f}_* \mid X, \mathbf{y}, X_*) \quad (15)$$

4.1 Distribusi Gabungan Prior (Joint Gaussian Prior)

Berdasarkan definisi dasar Gaussian Process, kumpulan observasi $\mathbf{y} \in \mathbb{R}^{N \times 1}$ dan fungsi laten test $\mathbf{f}_* \in \mathbb{R}^{N_* \times 1}$ secara bersama-sama membentuk distribusi Gaussian multivariat berdimensi $(N + N_*)$ (Rasmussen & Williams, 2006, hlm. 16, Persamaan (2.21)):

$$\begin{bmatrix} \mathbf{y} \\ \mathbf{f}_* \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mathbf{0}_{N \times 1} \\ \mathbf{0}_{N_* \times 1} \end{bmatrix}, \begin{bmatrix} K_y & K(X, X_*) \\ K(X_*, X) & K(X_*, X_*) \end{bmatrix} \right) \quad (16)$$

Struktur partisi blok matriks kovariansi pada Persamaan (16) diilustrasikan secara diagramatis pada Gambar 2.



Gambar 2: Diagram Partisi Blok Matriks Kovariansi Bersama (*Joint Covariance Matrix*). Matriks berukuran $(N + N_*) \times (N + N_*)$ terbagi menjadi 4 submatriks yang mencerminkan interaksi antara training data dan test data.

4.2 Distribusi Posterior Gaussian Process Regression

Dengan memanfaatkan teorema pengondisian Gaussian multivariat, distribusi posterior dari fungsi laten test $\mathbf{f}_*$ dengan syarat data observasi $(X, \mathbf{y})$ dirumuskan secara analitik:

Distribusi Posterior Gaussian Process Regression:

$$\mathbf{f}_* | X, \mathbf{y}, X_* \sim \mathcal{N}(\bar{\mathbf{f}}_*, \text{cov}(\mathbf{f}_*)) \quad (17)$$

$$\bar{\mathbf{f}}_* = K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} \mathbf{y} \in \mathbb{R}^{N_* \times 1} \quad (18)$$

$$\text{cov}(\mathbf{f}_*) = K(X_*, X_*) - K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} K(X, X_*) \in \mathbb{R}^{N_* \times N_*} \quad (19)$$

Untuk kasus test point tunggal $\mathbf{x}_* \in \mathbb{R}^{D \times 1}$ ($N_* = 1$), notasi disederhanakan dengan $\mathbf{k}_* = K(X, \mathbf{x}_*) \in \mathbb{R}^{N \times 1}$ dan skalar $k_{**} = k(\mathbf{x}_*, \mathbf{x}_*) \in \mathbb{R}$ (Rasmussen & Williams, 2006, hlm. 17, Persamaan (2.25)–(2.26)):

$$\bar{f}_* = \mathbf{k}_*^T K_y^{-1} \mathbf{y} \in \mathbb{R} \quad (\text{Dimensi: } (1 \times N) \times (N \times N) \times (N \times 1) = 1 \times 1) \quad (20)$$

$$\mathbb{V}[f_*] = k_{**} - \mathbf{k}_*^T K_y^{-1} \mathbf{k}_* \in \mathbb{R}^+ \quad (\text{Dimensi: } 1 - (1 \times N) \times (N \times N) \times (N \times 1) = 1 \times 1) \quad (21)$$

5 Worked Numerical Examples

“contoh_perhitungan.pdf”

Worked Numerical Examples: Gaussian Process Regression (GPR)

Tabel 1: Konvensi Notasi dan Dimensi Ruang Aljabar Linier.

Kategori Entitas	Simbol Contoh	Ruang Dimensi	Deskripsi / Peran Matematis
Jumlah Training Samples	N	$\mathbb{N}$	Skalar bulat: Banyaknya observasi dalam training dataset.
Jumlah Test Points	N_*	$\mathbb{N}$	Skalar bulat: Banyaknya lokasi target prediksi/inferensi.
Dimensi Input Fitur	D	$\mathbb{N}$	Skalar bulat: Banyaknya koordinat/fitur pada domain input.
Titik Input Observasi	$\mathbf{x}_i$	$\mathbb{R}^{D \times 1}$	Vektor kolom: Koordinat spasial atau fitur sampel ke- i .
Matriks Desain Training	X	$\mathbb{R}^{N \times D}$	Matriks training input bertumpuk, $X = [\mathbf{x}_1, \dots, \mathbf{x}_N]^T$.
Matriks Desain Test	X_*	$\mathbb{R}^{N_* \times D}$	Matriks input test point, $X_* = [\mathbf{x}_{*1}, \dots, \mathbf{x}_{*N_*}]^T$.
Target Observasi	y_i	$\mathbb{R}$	Skalar riil: Nilai target dengan galat pada titik $\mathbf{x}_i$.
Vektor Target Training	$\mathbf{y}$	$\mathbb{R}^{N \times 1}$	Vektor kolom observed training data, $\mathbf{y} = [y_1, \dots, y_N]^T$.
Fungsi Laten Training	$\mathbf{f}$	$\mathbb{R}^{N \times 1}$	Vektor nilai fungsi murni tanpa galat, $\mathbf{f} = [f(\mathbf{x}_1), \dots, f(\mathbf{x}_N)]^T$.
Vektor Galat Observasi	$\boldsymbol{\epsilon}$	$\mathbb{R}^{N \times 1}$	Vektor residu galat Gaussian, $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma_n^2 I_N)$.
Fungsi Laten Test	$\mathbf{f}_*$	$\mathbb{R}^{N_* \times 1}$	Vektor variabel acak nilai fungsi laten yang diprediksi.
Kovariansi Antar Training Data	$K(X, X)$	$\mathbb{R}^{N \times N}$	Matriks Gram simetris positif semi-definit dari fungsi kernel.
Kovariansi Total Training Data	K_y	$\mathbb{R}^{N \times N}$	Matriks kovariansi dengan galat, $K_y = K(X, X) + \sigma_n^2 I_N$.
Kovariansi Training-Test	$K(X, X_*)$	$\mathbb{R}^{N \times N_*}$	Matriks kovariansi silang antara training points dan test point.
Kovariansi Test-Training	$K(X_*, X)$	$\mathbb{R}^{N_* \times N}$	Transpose dari matriks silang, $K(X_*, X) = K(X, X_*)^T$.
Kovariansi Antar Test Points	$K(X_*, X_*)$	$\mathbb{R}^{N_* \times N_*}$	Matriks kovariansi internal antar sesama test point.
Faktor Cholesky	L	$\mathbb{R}^{N \times N}$	Matriks segitiga bawah riil (<i>lower triangular</i>), $K_y = LL^T$.
Vektor Bobot Prediktif	$\boldsymbol{\alpha}$	$\mathbb{R}^{N \times 1}$	Vektor solusi sistem linier, $\boldsymbol{\alpha} = K_y^{-1} \mathbf{y} = L^{-T} L^{-1} \mathbf{y}$.
Vektor Mean Prediktif	$\bar{\mathbf{f}}_*$	$\mathbb{R}^{N_* \times 1}$	Ekspektasi nilai fungsi posterior pada test point X_* .
Kovariansi Prediktif	$\text{cov}(\mathbf{f}_*)$	$\mathbb{R}^{N_* \times N_*}$	Matriks ketidakpastian posterior pada test point X_* .
Variansi Individual Test Point	$\mathbb{V}[f_{*j}]$	6 $\mathbb{R}^+$	Skalar variansi marjinal test point ke- j , yaitu $[\text{cov}(\mathbf{f}_*)]_{jj}$.