

BIMBINGAN TUGAS AKHIR #3

18 September 2026

1 Analisis Keterdiferensialan *Mean-Square* dan Spektrum Kehalusan Kernel

Melanjutkan fondasi regresi dan inferensi pada dokumen sebelumnya, bagian ini berfokus pada analisis analitik sifat kehalusan ruang fungsi (*mean-square differentiability*) yang ditentukan oleh struktur matematis fungsi kovariansi $k(\mathbf{x}, \mathbf{x}')$.

1.1 Perbandingan Analitik Jarak Linier r vs Jarak Kuadratik r^2

Diberikan dua titik input $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^{D \times 1}$ dengan jarak Euclidean $r = \|\mathbf{x} - \mathbf{x}'\|_2 = \sqrt{(\mathbf{x} - \mathbf{x}')^T (\mathbf{x} - \mathbf{x}')}$. Perbedaan perlakuan terhadap r menghasilkan sifat keterdiferensialan fungsi stokastik yang sangat kontras:

1. Kernel Squared Exponential (Berbasis r^2):

$$k_{\text{SE}}(r) = \sigma_f^2 \exp\left(-\frac{r^2}{2l^2}\right) \quad (1)$$

Pada $r = 0$, turunan pertama terhadap jarak bernilai nol:

$$\left. \frac{dk_{\text{SE}}}{dr} \right|_{r=0+} = -\frac{\sigma_f^2 r}{l^2} \exp\left(-\frac{r^2}{2l^2}\right) \Big|_{r=0+} = 0 \quad (2)$$

Karena fungsi kovariansi analitik pada titik asal ($r = 0$) dan memiliki turunan berhingga pada semua orde, proses Gaussian yang dihasilkan bersifat **terdiferensiasi tak hingga secara mean-square** (C^∞). Realisasi sampel fungsi dari kernel ini sangat mulus (*smooth*).


2. Kernel Exponential / Ornstein-Uhlenbeck (Berbasis r):

$$k_{\text{Exp}}(r) = \sigma_f^2 \exp\left(-\frac{r}{l}\right) \quad (3)$$

Pada $r = 0$, turunan satu sisi menghasilkan nilai konstan non-nol:

$$\left. \frac{dk_{\text{Exp}}}{dr} \right|_{r=0+} = -\frac{\sigma_f^2}{l} \neq 0 \quad (4)$$

Adanya sudut tajam (*cusp*) pada $r = 0$ menyebabkan proses stokastik **tidak terdiferensiasi secara mean-square** (C^0). Sampel fungsi kontinu namun sangat kasar (*jagged*), identik dengan lintasan Gerak Brown (*Brownian motion*) 1D.



Gambar 1: Profil kurva kovariansi $k(r)$ terhadap jarak Euclidean $r = \|\mathbf{x} - \mathbf{x}'\|$ ($l = 1.0, \sigma_f^2 = 1.0$).

1.2 Keluarga Matérn sebagai Spektrum Ruang Fungsi Sobolev

Keluarga kernel Matérn memfasilitasi parameterisasi eksplisit terhadap derajat keterdiferensialan proses stokastik melalui parameter $\nu > 0$:

$$k_{\text{Matérn}}(r) = \sigma_f^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\frac{\sqrt{2\nu} r}{l} \right)^\nu K_\nu \left(\frac{\sqrt{2\nu} r}{l} \right) \quad (5)$$

Proses stokastik $f(\mathbf{x})$ dengan kernel Matérn bersifat k -kali terdiferensiasi *mean-square* jika dan hanya jika $\nu > k$. Dengan memilih $\nu = p + 1/2$ ($p \in \mathbb{N}$), diperoleh spektrum kehalusan analitik:

- $\nu = 1/2$ (C^0 , Kasar): $k_{1/2}(r) = \sigma_f^2 \exp(-\frac{r}{l}) \equiv k_{\text{Exp}}(r)$
- $\nu = 3/2$ (C^1 , Sekali Terdiferensiasi): $k_{3/2}(r) = \sigma_f^2 \left(1 + \frac{\sqrt{3}r}{l}\right) \exp\left(-\frac{\sqrt{3}r}{l}\right)$
- $\nu = 5/2$ (C^2 , Dua Kali Terdiferensiasi): $k_{5/2}(r) = \sigma_f^2 \left(1 + \frac{\sqrt{5}r}{l} + \frac{5r^2}{3l^2}\right) \exp\left(-\frac{\sqrt{5}r}{l}\right)$
- Limit $\nu \rightarrow \infty$ (C^∞ , Mulus Tak Hingga): $\lim_{\nu \rightarrow \infty} k_{\text{Matérn}}(r) = k_{\text{SE}}(r)$


1.3 Analisis Pengaruh Hyperparameter Spasial

Dua hyperparameter utama mengendalikan geometri realisasi fungsi:


1. **Lengthscale** (l): Mengontrol frekuensi spasial fluktuasi fungsi. Nilai l yang kecil menghasilkan fungsi yang berosilasi cepat, sedangkan l yang besar memaksa fungsi menjadi lebih kaku dan lambat berubah.
2. **Signal Variance** (σ_f^2): Mengatur rentang amplitudo simpangan vertikal terhadap mean.

2 Mekanisme Generatif dan Sampling Fungsi via Dekomposisi Cholesky

Salah satu keunggulan utama dari perumusan *Gaussian Process* adalah kemampuannya untuk membangkitkan realisasi fungsi konkret (*function sampling*) dari distribusi ruang fungsi. Bagian ini menguraikan konsep fundamental, intuisi matematis, serta tahapan komputasi langkah demi langkah dari proses sampling tersebut.



Gambar 2: Realisasi sampel fungsi prior $f \sim \mathcal{GP}(0, k)$ memperlihatkan spektrum kehalusan dari C^0 hingga C^∞ .



Gambar 3: Simulasi efek hyperparameter: (Atas) Variasi $lengthscale\ l \in \{0.2, 1.0, 3.0\}$; (Bawah) Variasi $signal\ variance\ \sigma_f^2 \in \{0.25, 1.0, 4.0\}$.

2.1 Motivasi Fundamental dan Masalah Generatif

Secara fisik dan komputasional, sebuah komputer digital tidak dapat langsung membangkitkan “fungsi kontinu berdimensi tak hingga” secara utuh. Generator bilangan acak standar pada pustaka komputasi modern hanya mampu menghasilkan deret variabel acak Gaussian baku yang saling bebas (*independent standard normal random variables*):

$$u_i \sim \mathcal{N}(0, 1) \implies \mathbf{u} = [u_1, \dots, u_{N_*}]^T \sim \mathcal{N}(\mathbf{0}, I_{N_*}) \quad (6)$$

Jika vektor $\mathbf{u}$ ini di-plot secara langsung terhadap sumbu koordinat input, hasilnya hanyalah derau acak putih (*white noise*) yang terputus-putus dan tidak memiliki keterkaitan spasial sama sekali.

Tantangan Generatif : Bagaimana mentransformasikan vektor keacakan murni $\mathbf{u}$ yang tidak berkorelasi tersebut menjadi sebuah kurva kontinu $\mathbf{f}$ yang halus, bergelombang secara elegan, dan mematuhi struktur korelasi matriks kovariansi $K = k(X_*, X_*)$?

2.2 Jembatan Konseptual: Dari Skalar 1D Menuju Ruang Multivariat

Untuk memahami ide dasar penyelesaiannya, kita tinjau analogi transformasi variabel acak Gaussian satu dimensi (skalar) menuju multivariat:

1. **Kasus 1 Dimensi (Skalar)**: Jika kita memiliki variabel acak baku $u \sim \mathcal{N}(0, 1)$, kita dapat mengubahnya menjadi variabel acak target $x \sim \mathcal{N}(\mu, \sigma^2)$ melalui perkalian dengan *akar variansi* (standar deviasi σ) lalu digeser sebesar mean μ :

$$x = \mu + \sigma \cdot u \implies \mathbb{V}[x] = \mathbb{V}[\sigma u] = \sigma^2 \mathbb{V}[u] = \sigma^2(1) = \sigma^2 \quad (7)$$

2. **Kasus Multidimensi (Vektor Titik Fungsi)**: Pada ruang fungsi yang dievaluasi pada N_* titik, target kita adalah membangkitkan vektor $\mathbf{f} \sim \mathcal{N}(\mathbf{m}, K)$, di mana $K \in \mathbb{R}^{N_* \times N_*}$ adalah matriks kovariansi penuh. Analog dengan kasus 1D, kita membutuhkan sebuah “**matriks akar kuadrat**” L sedemikian sehingga:

$$K = LL^T \quad (8)$$

Persamaan faktorisasi ini diselesaikan secara unik melalui **Dekomposisi Cholesky**, di mana $L \in \mathbb{R}^{N_* \times N_*}$ adalah matriks segitiga bawah (*lower triangular matrix*) dengan entri diagonal positif ($L_{ii} > 0$). Vektor fungsi sampel kemudian dibangkitkan melalui transformasi linear:

$$\mathbf{f} = \mathbf{m} + L\mathbf{u} \quad (9)$$

2.3 Pembuktian Teoretis Transformasi Linear

Teorema 2.1 (Transformasi Linear Vektor Acak Gaussian). *Misalkan $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I_{N_*})$ adalah vektor acak Gaussian baku, dan $L \in \mathbb{R}^{N_* \times N_*}$ adalah matriks segitiga bawah hasil faktorisasi Cholesky dari matriks kovariansi simetris positif definit $K = LL^T$. Maka kombinasi afinitas $\mathbf{f} = \mathbf{m} + L\mathbf{u}$ berdistribusi eksak menurut Gaussian multivariat $\mathcal{N}(\mathbf{m}, K)$.*

Bukti. Distribusi Gaussian tertutup (*closed*) di bawah transformasi affine. Karakteristik distribusi $\mathbf{f}$ dibuktikan melalui momen pertama dan kedua terpusat:


1. **Nilai Harapan (Mean)**:

$$\mathbb{E}[\mathbf{f}] = \mathbb{E}[\mathbf{m} + L\mathbf{u}] = \mathbf{m} + L \mathbb{E}[\mathbf{u}] = \mathbf{m} + L(\mathbf{0}) = \mathbf{m} \quad (10)$$

2. Matriks Kovariansi:

$$\begin{aligned}
\text{cov}(\mathbf{f}) &= \mathbb{E} \left[(\mathbf{f} - \mathbb{E}[\mathbf{f}])(\mathbf{f} - \mathbb{E}[\mathbf{f}])^T \right] \\
&= \mathbb{E} \left[(L\mathbf{u})(L\mathbf{u})^T \right] = \mathbb{E} \left[L\mathbf{u}\mathbf{u}^T L^T \right] \\
&= L \mathbb{E} \left[\mathbf{u}\mathbf{u}^T \right] L^T = L I_{N_*} L^T = LL^T = K
\end{aligned} \tag{11}$$

Terbukti secara matematis bahwa $\mathbf{f} \sim \mathcal{N}(\mathbf{m}, K)$. □



Gambar 4: Visualisasi alur kerja komputasi sampling fungsi: (a) Matriks kovariansi Gram K ; (b) Faktor segitiga bawah Cholesky L ; (c) Pembangkitan derau acak independen $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I)$; (d) Realisasi kurva fungsi halus hasil transformasi linear $\mathbf{f} = L\mathbf{u}$.

2.4 Prosedur Sampling Langkah demi Langkah Beserta Alasannya

Secara komputasional, proses pengambilan sampel dari distribusi Gaussian Process dieksekusi melalui lima tahapan berikut:

1. Langkah 1: Diskritisasi Domain Input (X_*)

- *Tindakan*: Menentukan N_* titik koordinat evaluasi pada domain input yang tersusun rapat, $X_* = [\mathbf{x}_{*1}, \dots, \mathbf{x}_{*N_*}]^T \in \mathbb{R}^{N_* \times D}$.
- *Alasan*: Komputer tidak dapat mengevaluasi domain kontinu secara tak hingga titik, sehingga fungsi diwakili oleh sampel titik diskret berkepadatan tinggi.

2. Langkah 2: Evaluasi Matriks Kovariansi ($K = k(X_*, X_*)$)

- *Tindakan*: Menghitung nilai kernel $K_{ij} = k(\mathbf{x}_{*i}, \mathbf{x}_{*j})$ untuk setiap pasangan titik uji.
- *Alasan*: Matriks K bertindak sebagai “pemberi aturan korelasi”. Pasangan titik yang berjarak sangat dekat memiliki nilai kovariansi mendekati σ_f^2 (dipaksa bernilai mirip), sedangkan titik yang berjauhan memiliki kovariansi mendekati 0.

3. Langkah 3: Stabilisasi Numerik dan Dekomposisi Cholesky

- *Tindakan*: Menambahkan konstanta kestabilan (*jitter*) $\tilde{K} = K + \epsilon_{\text{jitter}} I_{N_*}$ ($\epsilon_{\text{jitter}} = 10^{-6}$), kemudian menghitung matriks segitiga bawah $L = \text{cholesky}(\tilde{K})$.
- *Alasan*: Dekomposisi Cholesky memiliki kompleksitas komputasi yang sangat efisien ($\frac{1}{3}N_*^3$ FLOPs) dan hanya terdefinisi pada matriks definit positif. Penambahan *jitter* mencegah kegagalan dekomposisi akibat galat pembulatan floating-point pada matriks dengan kondisi buruk (*ill-conditioned*).

4. Langkah 4: Pembangkitan Vektor Keacakan Murni ($\mathbf{u}$)

- *Tindakan*: Mengambil N_* bilangan acak independen $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I_{N_*})$.
- *Alasan*: Vektor $\mathbf{u}$ menyediakan variasi stokastik murni. Setiap sampel kurva baru yang ingin dibuat cukup dibangkitkan dari vektor $\mathbf{u}$ acak yang baru.

5. Langkah 5: Transformasi Linear ($\mathbf{f} = \mathbf{m} + L\mathbf{u}$)

- *Tindakan*: Mengalikan matriks segitiga bawah L dengan vektor acak $\mathbf{u}$ dan menambahkan vektor mean $\mathbf{m}$.
- *Alasan*: Operasi perkalian matriks $L\mathbf{u}$ berfungsi mengikat (*mixing*) variabel-variabel acak independen tadi dengan bobot-bobot kovariansi pada baris matriks L , sehingga menghasilkan realisasi kurva yang kontinu dan mulus.

2.5 Sampling Prior versus Sampling Posterior

Mekanisme sampling di atas berlaku identik baik untuk distribusi sebelum observasi data (**Prior**) maupun sesudah observasi data (**Posterior**):

- **Sampling Prior**: Menggunakan $\mathbf{m}_* = \mathbf{0}$ dan matriks kovariansi $K_* = K(X_*, X_*)$. Seluruh sampel fungsi berfluktuasi bebas di dalam pita ketidakpastian seragam $\pm 2\sigma_f$.
- **Sampling Posterior** (Terkondisi pada data training $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$): Menggunakan mean prediktif $\bar{\mathbf{f}}_*$ dan matriks kovariansi prediktif Σ_* :

$$\bar{\mathbf{f}}_* = K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} \mathbf{y} \quad (12)$$

$$\Sigma_* = K(X_*, X_*) - K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} K(X, X_*) \quad (13)$$

Faktorisasi Cholesky diterapkan pada kovariansi prediktif: $L_{\text{post}} = \text{cholesky}(\Sigma_* + \epsilon I)$. Sampel posterior dihitung melalui:

$$\mathbf{f}_{*,\text{post}}^{(s)} = \bar{\mathbf{f}}_* + L_{\text{post}} \mathbf{u}^{(s)} \quad (14)$$

Pada lokasi titik di dekat training data, variansi pada Σ_* bernilai mendekati nol ($L_{\text{post}} \approx \mathbf{0}$), sehingga seluruh realisasi sampel fungsi terkunci rapat dan dipaksa melewati nilai target observasi y_i .


2.6 Analisis Kestabilan Numerik dan Penanganan *Jitter*

Pada kernel stasioner dengan kehalusan tinggi (C^∞) atau evaluasi grid padat, jarak antar titik evaluasi tetangga sangat kecil ($|x_i - x_{i+1}| \rightarrow 0$). Akibatnya, baris-baris pada matriks K menjadi hampir linier dependen (*nearly collinear*), menyebabkan rasio nilai eigen ekstrim ($\kappa(K) = \lambda_{\max}/\lambda_{\min} \gg 10^{12}$).

Galat pembulatan floating-point IEEE 754 dapat memicu nilai eigen terkecil secara semu menjadi nol atau negatif ($\lambda_{\min} \leq 0$). Penambahan suku regularisasi diagonal (*jitter*) $\epsilon_{\text{jitter}} I$ secara matematis menggeser seluruh spektrum nilai eigen:

$$\lambda_i(\tilde{K}) = \lambda_i(K) + \epsilon_{\text{jitter}} > 0 \quad (15)$$

Hal ini menjamin matriks tetap berstatus definit positif secara numerik tanpa mengubah korelasi spasial antar titik yang berbeda. Nilai $\epsilon_{\text{jitter}} \in [10^{-6}, 10^{-4}]$ terbukti optimal dalam menjaga stabilitas komputasi.



Gambar 5: Evolusi realisasi sampel fungsi: (Kiri) Sampel prior berosilasi bebas dengan ketidakpastian merata; (Kanan) Sampel posterior terkonsentrasi rapat mengikuti data observasi training.

3 Keterbatasan Kernel Stasioner dan Motivasi Deep Gaussian Process

Analisis pada bagian sebelumnya menunjukkan bahwa kernel stasioner standar memaksakan asumsi ketergantungan spasial yang seragam di seluruh ruang input. Pada tugas segmentasi citra (*Image Segmentation*), karakteristik ini menghadapi tantangan fundamental:

1. **Ketidakteraturan Spasial (*Spatial Non-Stationarity*)**: Citra terdiri dari wilayah latar homogen berdampingan dengan tepi objek tajam (*sharp object edges*). Kernel stasioner tunggal memicu fenomena *over-smoothing*, di mana batas segmen piksel menjadi kabur.
2. **Arsitektur Deep Gaussian Process (DGP)**: Untuk memodelkan fungsi non-stasioner tanpa merancang kernel manual yang rumit, DGP menyusun hirarki komposisi proses stokastik laten:

$$\mathbf{y} = f_L(f_{L-1}(\dots f_1(\mathbf{x}) \dots)), \quad \text{dengan } f_\ell \sim \mathcal{GP}(m_\ell, k_\ell) \quad (16)$$

Lapisan-lapisan GP laten awal bertindak sebagai transformasi non-linear ruang input (*input space warping*), mentranslasikan koordinat spasial piksel menjadi representasi manifold laten non-stasioner sebelum dievaluasi pada lapisan klasifikasi segmentasi.

3. **Propagasi Ketidakpastian via Sampling**: Inferensi pada DGP mengandalkan propagasi sampel fungsi antar lapisan laten via faktorisasi Cholesky dan aproksimasi variasional (*Variational Inference*), menjadikan pemahaman sampling fungsi sebagai kunci utama implementasi sistem.

Pustaka

- [1] Rasmussen, C. E., & Williams, C. K. (2006). *Gaussian Processes for Machine Learning*. MIT Press, Cambridge, MA.
- [2] Damianou, A., & Lawrence, N. D. (2013). Deep Gaussian Processes. *Proceedings of the 16th International Conference on Artificial Intelligence and Statistics (AISTATS)*, PMLR 31:207-215.
- [3] Salimbeni, H., & Deisenroth, M. (2017). Doubly Stochastic Variational Inference for Deep Gaussian Processes. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.