

BIMBINGAN TUGAS AKHIR #3

19 September 2026

1 Karakteristik Fungsi Kovariansi (Kernel) dan Eksplorasi Hyperparameter

Melanjutkan fondasi regresi dan inferensi pada dokumen sebelumnya, bagian ini menyajikan taksonomi komprehensif fungsi kovariansi (*kernel*) berdasarkan buku teks standar *Gaussian Processes for Machine Learning* (Rasmussen & Williams, 2006), peran fisis dari masing-masing hyperparameter, serta analisis empiris melalui eksperimen komputasi.

1.1 Definisi Formal dan Klasifikasi Sifat Kernel

Definisi 1.1 (Fungsi Kovariansi / Kernel). *Diberikan domain input $\mathcal{X} \subseteq \mathbb{R}^D$, fungsi kovariansi $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ adalah fungsi bernilai riil yang memetakan pasangan titik input $(\mathbf{x}, \mathbf{x}')$ menjadi nilai kovariansi antara variabel acak fungsi laten $f(\mathbf{x})$ dan $f(\mathbf{x}')$:*

$$k(\mathbf{x}, \mathbf{x}') = \text{cov}(f(\mathbf{x}), f(\mathbf{x}')) = \mathbb{E}[(f(\mathbf{x}) - m(\mathbf{x}))(f(\mathbf{x}') - m(\mathbf{x}'))] \quad (1)$$

Syarat Keabsahan Kernel : Agar fungsi $k(\mathbf{x}, \mathbf{x}')$ merupakan fungsi kovariansi yang sah, matriks Gram $K \in \mathbb{R}^{N \times N}$ dengan elemen $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ harus bersifat **Simetris dan Positif Semidefinit** (*Positive Semi-Definite* / PSD), yaitu:

$$\mathbf{v}^T K \mathbf{v} \geq 0, \quad \forall \mathbf{v} \in \mathbb{R}^N \setminus \{\mathbf{0}\} \quad (2)$$

Sifat PSD menjamin bahwa variansi dari kombinasi linear fungsi laten tidak pernah bernilai negatif.

Klasifikasi Sifat Geometris Kernel :

1. **Kernel Stasioner**: Fungsi kovariansi invarian terhadap translasi pada ruang input, yaitu nilai kovariansi hanya bergantung pada vektor selisih $\boldsymbol{\tau} = \mathbf{x} - \mathbf{x}'$:

$$k(\mathbf{x}, \mathbf{x}') = k(\mathbf{x} - \mathbf{x}') = k(\boldsymbol{\tau}) \quad (3)$$

2. **Kernel Isotropik**: Subkelas dari kernel stasioner di mana kovariansi bersifat invarian terhadap rotasi dan hanya bergantung pada jarak skalar Euclidean $r = \|\mathbf{x} - \mathbf{x}'\|_2$:

$$k(\mathbf{x}, \mathbf{x}') = k(\|\mathbf{x} - \mathbf{x}'\|_2) = k(r) \quad (4)$$

3. **Kernel Non-Stasioner**: Nilai kovariansi bergantung secara eksplisit pada lokasi absolut titik $\mathbf{x}$ dan $\mathbf{x}'$ di ruang input (contoh: fungsi berbasis produk titik $\mathbf{x}^T \mathbf{x}'$).

1.2 Katalog Fungsi Kovariansi Buku Teks Rasmussen & Williams

Berdasarkan Rasmussen & Williams (2006) (Bab 4 dan Tabel 4.1), fungsi-fungsi kovariansi standar yang fundamental terangkum dalam Tabel 1.

Nama Kernel	Formula Matematis $k(r)$ / $k(\mathbf{x}, \mathbf{x}')$	Sifat	Hyperparameter
Squared Exponential	$\sigma_f^2 \exp\left(-\frac{r^2}{2l^2}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Matérn ($\nu = 3/2$)	$\sigma_f^2 \left(1 + \frac{\sqrt{3}r}{l}\right) \exp\left(-\frac{\sqrt{3}r}{l}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Matérn ($\nu = 5/2$)	$\sigma_f^2 \left(1 + \frac{\sqrt{5}r}{l} + \frac{5r^2}{3l^2}\right) \exp\left(-\frac{\sqrt{5}r}{l}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Exponential ($\nu = 1/2$)	$\sigma_f^2 \exp\left(-\frac{r}{l}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Rational Quadratic	$\sigma_f^2 \left(1 + \frac{r^2}{2\alpha l^2}\right)^{-\alpha}$	Stasioner	$l > 0, \sigma_f^2 > 0, \alpha > 0$
γ-Exponential	$\sigma_f^2 \exp\left(-\left(\frac{r}{l}\right)^\gamma\right)$	Stasioner	$l > 0, \sigma_f^2 > 0, \gamma \in (0, 2]$
Periodic	$\sigma_f^2 \exp\left(-\frac{2 \sin^2(\pi r/p)}{l^2}\right)$	Stasioner	$p > 0, l > 0, \sigma_f^2 > 0$
Cosine	$\sigma_f^2 \cos\left(\frac{2\pi r}{p}\right)$	Stasioner	$p > 0, \sigma_f^2 > 0$
Linear (Dot Product)	$\sigma_b^2 + \sigma_v^2(\mathbf{x} - c)(\mathbf{x}' - c)$	Non-stasioner	$\sigma_b^2 \geq 0, \sigma_v^2 > 0, c \in \mathbb{R}$
Neural Network (Erf)	$\sigma_f^2 \frac{2}{\pi} \arcsin\left(\frac{2\tilde{\mathbf{x}}^T \Sigma \tilde{\mathbf{x}'}}{\sqrt{(1+2\tilde{\mathbf{x}}^T \Sigma \tilde{\mathbf{x}})(1+2\tilde{\mathbf{x}}'^T \Sigma \tilde{\mathbf{x}'})}}\right)$	Non-stasioner	$\Sigma = \text{diag}(\sigma_0^2, \sigma_v^2), \sigma_f^2 > 0$
White Noise	$\sigma_n^2 \delta(\mathbf{x} - \mathbf{x}')$	Stasioner	$\sigma_n^2 > 0$

Tabel 1: Katalog fungsi kovariansi standar dari buku teks Rasmussen & Williams (2006).

1.3 Analisis Efek Fisis dan Geometri Hyperparameter

Hyperparameter pada fungsi kovariansi bertindak sebagai pengendali utama ruang fungsi prior $\mathcal{GP}(0, k)$. Karakteristik fisis dari masing-masing parameter diuraikan sebagai berikut:

1. **Lengthscale** (l): Mengatur skala jarak spasial di mana dua titik masukan saling mempertahankan korelasi yang signifikan.
 - Nilai l kecil: Kovariansi meluruh dengan sangat cepat seiring bertambahnya jarak. Fungsi berfluktuasi dengan frekuensi spasial tinggi.
 - Nilai l besar: Titik-titik yang berjauhan tetap berkorelasi kuat, memaksa kurva fungsi menjadi kaku, datar, dan lambat berubah.
2. **Signal Variance** (σ_f^2): Mengatur skala variansi vertikal (amplitudo) fungsi di sekitar mean $m(\mathbf{x}) = 0$. Karena $\text{Var}[f(\mathbf{x})] = k(\mathbf{x}, \mathbf{x}) = \sigma_f^2$, parameter ini menentukan lebar rentang simpangan kurva sampel ($\pm 2\sigma_f$ untuk pita kepercayaan 95%).
3. **Scale Mixture** (α) pada **Rational Quadratic**: Kernel RQ merepresentasikan superposisi kontinu dari kernel Squared Exponential dengan berbagai variasi *lengthscale*:

$$k_{\text{RQ}}(r) = \int_0^\infty \exp\left(-\frac{\tau r^2}{2}\right) p(\tau; \alpha, l) d\tau, \quad \tau = l^{-2} \sim \text{Gamma}(\alpha, \alpha l_0^2) \quad (5)$$


Nilai α kecil mengizinkan variasi multi-skala (fluktuasi lokal cepat berdampingan dengan tren global lambat). Ketika $\alpha \rightarrow \infty$, kernel RQ mereduksi tepat ke kernel Squared Exponential dengan skala tunggal l_0 .

4. **Periode** (p) pada **Periodic & Cosine**: Menentukan panjang gelombang spasial perubahan siklus ($f(x+p) \approx f(x)$). Parameter l pada kernel periodik mengatur elastisitas kehalusan gelombang di dalam satu siklus.

5. **Titik Tumpu (c) dan Variansi Kemiringan (σ_v^2) pada Linear Kernel:** Menghasilkan variansi prior non-stasioner $\text{Var}[f(x)] = \sigma_b^2 + \sigma_v^2(x - c)^2$. Variansi bernilai minimum pada titik $x = c$ dan melebar secara kuadratik membentuk corong ketidakpastian (*fan shape*) seiring menjauh dari c .
6. **Bobot Parameter $\Sigma = \text{diag}(\sigma_0^2, \sigma_v^2)$ pada Neural Network Kernel:** Williams (1998) membuktikan bahwa kernel ini ekuivalen dengan jaringan saraf tiruan lapis tunggal dengan jumlah unit tersembunyi tak terhingga (Rasmussen & Williams, 2006). Parameter σ_0^2 mengontrol variansi bias dan σ_v^2 mengontrol kecuraman transisi sigmoid antar daerah domain.

1.4 Hasil Eksperimen Komputasi dan Visualisasi Ruang Fungsi

Untuk memvalidasi pemahaman teoretis di atas, dilakukan serangkaian simulasi komputasi numerik.




Gambar 1: Profil kurva kovariansi $k(r)$ terhadap jarak Euclidean $r = \|\mathbf{x} - \mathbf{x}'\|$: (a) Perbandingan peluruhan kovariansi kernel stasioner isotropik; (b) Karakteristik osilasi siklik kernel periodik dan kosinus.

Gambar 1 memperlihatkan bagaimana profil $k(r)$ meluruh terhadap jarak Euclidean r . Pada kernel Squared Exponential dan Matérn, kurva meluruh monotonik dari nilai puncak $k(0) = \sigma_f^2 = 1.0$ menuju 0, sedangkan kernel periodik mempertahankan korelasi berulang secara periodik pada jarak kelipatan p .


Gambar 2 menampilkan galeri 4 realisasi kurva sampel fungsi prior acak $\mathbf{f} \sim \mathcal{GP}(0, K)$ untuk masing-masing kelas kernel. Terlihat jelas bahwa kernel stasioner (SE, Matérn, RQ, Periodic) menghasilkan variansi yang seragam di seluruh ruang input, sementara kernel non-stasioner (Linear dan Neural Network) memperlihatkan variansi fungsi yang berubah secara dramatis tergantung posisi koordinat x .

Hasil eksperimen variasi nilai hyperparameter pada Gambar 3 menegaskan peran geometris setiap parameter:

- **Panel (a) & (b):** Variasi $l \in \{0.3, 1.0, 2.5\}$ mengubah frekuensi osilasi horizontal secara drastis, sementara variasi $\sigma_f^2 \in \{0.25, 1.0, 4.0\}$ mengubah skala vertikal kurva.
- **Panel (c):** Nilai $\alpha = 0.1$ pada RQ menghasilkan fungsi yang memuat variasi detail lokal mikro di atas gelombang makro, sementara $\alpha = 20.0$ menghasilkan kurva yang identik dengan SE skala tunggal.
- **Panel (d):** Variasi $p \in \{1.0, 2.0, 4.0\}$ mengubah jarak spasial antar puncak gelombang periodik.



Gambar 2: Galeri realisasi sampel fungsi prior $f \sim \mathcal{GP}(0, K)$ yang dibangkitkan dari 6 kelas kernel berbeda dari buku teks Rasmussen & Williams.



Gambar 3: Eksperimen komputasi pengaruh variasi nilai hyperparameter pada fungsi prior: (a) Variasi l pada SE; (b) Variasi σ_f^2 pada SE; (c) Variasi α pada RQ; (d) Variasi p pada Periodic; (e) Variasi c pada Linear; (f) Variasi σ_v pada Neural Network.

- **Panel (e) & (f):** Pergeseran nilai $c \in \{-1.5, 0.0, 1.5\}$ menggeser titik tumpu variansi minimum garis linear, sedangkan pembesaran σ_v pada Neural Network kernel mempertegas daerah transisi non-linear.

2 Mekanisme Generatif dan Sampling Fungsi via Dekomposisi Cholesky

Salah satu keunggulan utama dari perumusan *Gaussian Process* adalah kemampuannya untuk membangkitkan realisasi fungsi konkret (*function sampling*) dari distribusi ruang fungsi. Bagian ini menguraikan konsep fundamental, intuisi matematis, serta tahapan komputasi langkah demi langkah dari proses sampling tersebut.

2.1 Motivasi Fundamental dan Masalah Generatif

Secara fisik dan komputasional, sebuah komputer digital tidak dapat langsung membangkitkan “fungsi kontinu berdimensi tak hingga” secara utuh. Generator bilangan acak standar pada pustaka komputasi modern hanya mampu menghasilkan deret variabel acak Gaussian baku yang saling bebas (*independent standard normal random variables*):

$$u_i \sim \mathcal{N}(0, 1) \implies \mathbf{u} = [u_1, \dots, u_{N_*}]^T \sim \mathcal{N}(\mathbf{0}, I_{N_*}) \quad (6)$$

Jika vektor $\mathbf{u}$ ini di-plot secara langsung terhadap sumbu koordinat input, hasilnya hanyalah derau acak putih (*white noise*) yang terputus-putus dan tidak memiliki keterkaitan spasial sama sekali.

Tantangan Generatif : Bagaimana mentransformasikan vektor keacakan murni $\mathbf{u}$ yang tidak berkorelasi tersebut menjadi sebuah kurva kontinu $\mathbf{f}$ yang halus, bergelombang secara elegan, dan mematuhi struktur korelasi matriks kovariansi $K = k(X_*, X_*)$?

2.2 Jembatan Konseptual: Dari Skalar 1D Menuju Ruang Multivariat

Untuk memahami ide dasar penyelesaiannya, kita tinjau analogi transformasi variabel acak Gaussian satu dimensi (skalar) menuju multivariat:

1. **Kasus 1 Dimensi (Skalar)**: Jika kita memiliki variabel acak baku $u \sim \mathcal{N}(0, 1)$, kita dapat mengubahnya menjadi variabel acak target $x \sim \mathcal{N}(\mu, \sigma^2)$ melalui perkalian dengan *akar variansi* (standar deviasi σ) lalu digeser sebesar mean μ :

$$x = \mu + \sigma \cdot u \implies \mathbb{V}[x] = \mathbb{V}[\sigma u] = \sigma^2 \mathbb{V}[u] = \sigma^2(1) = \sigma^2 \quad (7)$$

2. **Kasus Multidimensi (Vektor Titik Fungsi)**: Pada ruang fungsi yang dievaluasi pada N_* titik, target kita adalah membangkitkan vektor $\mathbf{f} \sim \mathcal{N}(\mathbf{m}, K)$, di mana $K \in \mathbb{R}^{N_* \times N_*}$ adalah matriks kovariansi penuh. Analog dengan kasus 1D, kita membutuhkan sebuah “**matriks akar kuadrat**” L sedemikian sehingga:

$$K = LL^T \quad (8)$$

Persamaan faktorisasi ini diselesaikan secara unik melalui **Dekomposisi Cholesky**, di mana $L \in \mathbb{R}^{N_* \times N_*}$ adalah matriks segitiga bawah (*lower triangular matrix*) dengan entri diagonal positif ($L_{ii} > 0$). Vektor fungsi sampel kemudian dibangkitkan melalui transformasi linear:

$$\mathbf{f} = \mathbf{m} + L\mathbf{u} \quad (9)$$

2.3 Pembuktian Teoretis Transformasi Linear

Teorema 2.1 (Transformasi Linear Vektor Acak Gaussian). Misalkan $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I_{N_*})$ adalah vektor acak Gaussian baku, dan $L \in \mathbb{R}^{N_* \times N_*}$ adalah matriks segitiga bawah hasil faktorisasi Cholesky dari matriks kovariansi simetris positif definit $K = LL^T$. Maka kombinasi afinitas $\mathbf{f} = \mathbf{m} + L\mathbf{u}$ berdistribusi eksak menurut Gaussian multivariat $\mathcal{N}(\mathbf{m}, K)$.

Bukti. Distribusi Gaussian tertutup (*closed*) di bawah transformasi affine. Karakteristik distribusi $\mathbf{f}$ dibuktikan melalui momen pertama dan kedua terpusat:


1. Nilai Harapan (Mean):

$$\mathbb{E}[\mathbf{f}] = \mathbb{E}[\mathbf{m} + L\mathbf{u}] = \mathbf{m} + L \mathbb{E}[\mathbf{u}] = \mathbf{m} + L(\mathbf{0}) = \mathbf{m} \quad (10)$$

2. Matriks Kovariansi:

$$\begin{aligned} \text{cov}(\mathbf{f}) &= \mathbb{E}[(\mathbf{f} - \mathbb{E}[\mathbf{f}])(\mathbf{f} - \mathbb{E}[\mathbf{f}])^T] \\ &= \mathbb{E}[(L\mathbf{u})(L\mathbf{u})^T] = \mathbb{E}[L\mathbf{u}\mathbf{u}^T L^T] \\ &= L \mathbb{E}[\mathbf{u}\mathbf{u}^T] L^T = L I_{N_*} L^T = LL^T = K \end{aligned} \quad (11)$$

Terbukti secara matematis bahwa $\mathbf{f} \sim \mathcal{N}(\mathbf{m}, K)$. □



Gambar 4: Visualisasi alur kerja komputasi sampling fungsi: (a) Matriks kovariansi Gram K ; (b) Faktor segitiga bawah Cholesky L ; (c) Pembangkitan derau acak independen $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I)$; (d) Realisasi kurva fungsi halus hasil transformasi linear $\mathbf{f} = L\mathbf{u}$.

2.4 Prosedur Sampling Langkah demi Langkah Beserta Alasannya

Secara komputasional, proses pengambilan sampel dari distribusi Gaussian Process dieksekusi melalui lima tahapan berikut:

1. Langkah 1: Diskritisasi Domain Input (X_*)

- *Tindakan:* Menentukan N_* titik koordinat evaluasi pada domain input yang tersusun rapat, $X_* = [\mathbf{x}_{*1}, \dots, \mathbf{x}_{*N_*}]^T \in \mathbb{R}^{N_* \times D}$.
- *Alasan:* Komputer tidak dapat mengevaluasi domain kontinu secara tak hingga titik, sehingga fungsi diwakili oleh sampel titik diskret berkepadatan tinggi.

2. Langkah 2: Evaluasi Matriks Kovariansi ($K = k(X_*, X_*)$)

- *Tindakan:* Menghitung nilai kernel $K_{ij} = k(\mathbf{x}_{*i}, \mathbf{x}_{*j})$ untuk setiap pasangan titik uji.
- *Alasan:* Matriks K bertindak sebagai “pemberi aturan korelasi”. Pasangan titik yang berjarak sangat dekat memiliki nilai kovariansi mendekati σ_f^2 (dipaksa bernilai mirip), sedangkan titik yang berjauhan memiliki kovariansi mendekati 0.

3. Langkah 3: Stabilisasi Numerik dan Dekomposisi Cholesky

- *Tindakan*: Menambahkan konstanta kestabilan (*jitter*) $\tilde{K} = K + \epsilon_{\text{jitter}} I_{N_*}$ ($\epsilon_{\text{jitter}} = 10^{-6}$), kemudian menghitung matriks segitiga bawah $L = \text{cholesky}(\tilde{K})$.
- *Alasan*: Dekomposisi Cholesky memiliki kompleksitas komputasi yang sangat efisien ($\frac{1}{3}N_*^3$ FLOPs) dan hanya terdefinisi pada matriks definit positif. Penambahan *jitter* mencegah kegagalan dekomposisi akibat galat pembulatan floating-point pada matriks dengan kondisi buruk (*ill-conditioned*).

4. Langkah 4: Pembangkitan Vektor Keacakan Murni ($\mathbf{u}$)

- *Tindakan*: Mengambil N_* bilangan acak independen $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I_{N_*})$.
- *Alasan*: Vektor $\mathbf{u}$ menyediakan variasi stokastik murni. Setiap sampel kurva baru yang ingin dibuat cukup dibangkitkan dari vektor $\mathbf{u}$ acak yang baru.

5. Langkah 5: Transformasi Linear ($\mathbf{f} = \mathbf{m} + L\mathbf{u}$)

- *Tindakan*: Mengalikan matriks segitiga bawah L dengan vektor acak $\mathbf{u}$ dan menambahkan vektor mean $\mathbf{m}$.
- *Alasan*: Operasi perkalian matriks $L\mathbf{u}$ berfungsi mengikat (*mixing*) variabel-variabel acak independen tadi dengan bobot-bobot kovariansi pada baris matriks L , sehingga menghasilkan realisasi kurva yang kontinu dan mulus.

2.5 Sampling Prior versus Sampling Posterior

Mekanisme sampling di atas berlaku identik baik untuk distribusi sebelum observasi data (**Prior**) maupun sesudah observasi data (**Posterior**):

- **Sampling Prior**: Menggunakan $\mathbf{m}_* = \mathbf{0}$ dan matriks kovariansi $K_* = K(X_*, X_*)$. Seluruh sampel fungsi berfluktuasi bebas di dalam pita ketidakpastian seragam $\pm 2\sigma_f$.
- **Sampling Posterior** (Terkondisi pada data training $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$): Menggunakan mean prediktif $\bar{\mathbf{f}}_*$ dan matriks kovariansi prediktif Σ_* :

$$\bar{\mathbf{f}}_* = K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} \mathbf{y} \quad (12)$$

$$\Sigma_* = K(X_*, X_*) - K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} K(X, X_*) \quad (13)$$

Faktorisasi Cholesky diterapkan pada kovariansi prediktif: $L_{\text{post}} = \text{cholesky}(\Sigma_* + \epsilon I)$. Sampel posterior dihitung melalui:

$$\mathbf{f}_{*,\text{post}}^{(s)} = \bar{\mathbf{f}}_* + L_{\text{post}} \mathbf{u}^{(s)} \quad (14)$$


Pada lokasi titik di dekat training data, variansi pada Σ_* bernilai mendekati nol ($L_{\text{post}} \approx \mathbf{0}$), sehingga seluruh realisasi sampel fungsi terkunci rapat dan dipaksa melewati nilai target observasi y_i .

2.6 Analisis Kestabilan Numerik dan Penanganan *Jitter*

Pada evaluasi grid padat, jarak antar titik evaluasi tetangga sangat kecil ($|x_i - x_{i+1}| \rightarrow 0$). Akibatnya, baris-baris pada matriks K menjadi hampir linier dependen (*nearly collinear*), menyebabkan rasio nilai eigen ekstrim ($\kappa(K) = \lambda_{\max}/\lambda_{\min} \gg 10^{12}$).

Galat pembulatan floating-point IEEE 754 dapat memicu nilai eigen terkecil secara semu menjadi nol atau negatif ($\lambda_{\min} \leq 0$). Penambahan suku regularisasi diagonal (*jitter*) $\epsilon_{\text{jitter}} I$ secara matematis menggeser seluruh spektrum nilai eigen:

$$\lambda_i(\tilde{K}) = \lambda_i(K) + \epsilon_{\text{jitter}} > 0 \quad (15)$$



Gambar 5: Evolusi realisasi sampel fungsi: (Kiri) Sampel prior beresilasi bebas dengan ketidakpastian merata; (Kanan) Sampel posterior terkonsentrasi rapat mengikuti data observasi training.

Hal ini menjamin matriks tetap berstatus definit positif secara numerik tanpa merusak integritas korelasi spasial antar titik yang berbeda. Nilai $\epsilon_{\text{jitter}} \in [10^{-6}, 10^{-4}]$ terbukti optimal dalam menjaga stabilitas komputasi.

3 Keterbatasan Kernel Stasioner dan Motivasi Deep Gaussian Process

Analisis pada bagian sebelumnya menunjukkan bahwa kernel stasioner standar memaksakan asumsi ketergantungan spasial yang seragam di seluruh ruang input. Pada tugas segmentasi citra (*Image Segmentation*), karakteristik ini menghadapi tantangan fundamental:

1. **Ketidakteraturan Spasial (*Spatial Non-Stationarity*)**: Citra terdiri dari wilayah latar homogen berdampingan dengan tepi objek tajam (*sharp object edges*). Kernel stasioner tunggal memicu fenomena *over-smoothing*, di mana batas segmen piksel menjadi kabur.
2. **Arsitektur Deep Gaussian Process (DGP)**: Untuk memodelkan fungsi non-stasioner tanpa merancang kernel manual yang rumit, DGP menyusun hirarki komposisi proses stokastik laten:

$$\mathbf{y} = f_L(f_{L-1}(\dots f_1(\mathbf{x}) \dots)), \quad \text{dengan } f_\ell \sim \mathcal{GP}(m_\ell, k_\ell) \quad (16)$$

Lapisan-lapisan GP laten awal bertindak sebagai transformasi non-linear ruang input (*input space warping*), mentranslasikan koordinat spasial piksel menjadi representasi manifold laten non-stasioner sebelum dievaluasi pada lapisan klasifikasi segmentasi.

3. **Propagasi Ketidakpastian via Sampling**: Inferensi pada DGP mengandalkan propagasi sampel fungsi antar lapisan laten via faktorisasi Cholesky dan aproksimasi variasional (*Variational Inference*), menjadikan pemahaman sampling fungsi sebagai kunci utama implementasi sistem.

Pustaka

- [1] Rasmussen, C. E., & Williams, C. K. (2006). *Gaussian Processes for Machine Learning*. MIT Press, Cambridge, MA.

- [2] Neal, R. M. (1995). *Bayesian Learning for Neural Networks*. Ph.D. thesis, University of Toronto.
- [3] Williams, C. K. (1998). Computation with infinite neural networks. *Neural Computation*, 10(5), 1203-1216.
- [4] Damianou, A., & Lawrence, N. D. (2013). Deep Gaussian Processes. *Proceedings of the 16th International Conference on Artificial Intelligence and Statistics (AISTATS)*, PMLR 31:207-215.
- [5] Salimbeni, H., & Deisenroth, M. (2017). Doubly Stochastic Variational Inference for Deep Gaussian Processes. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.