

BIMBINGAN TUGAS AKHIR #3

23 September 2026

1 Mencari Sample dari Distribusi Gaussian Process

Sampel fungsi berkorelasi dapat dibangkitkan dari *random noise* independen berkat sifat distribusi Gaussian multivariat yang tetap berdistribusi Gaussian saat dikenai *affine transformation*:

Teorema 1.1 (Transformasi Affine Vektor Acak Gaussian (Hogg, McKean, & Craig, 2013)). *Jika $\mathbf{u} \sim \mathcal{N}(\mu_u, \Sigma_u)$ adalah vektor acak Gaussian berdimensi n , dan diberikan matriks transformasi konstan $A \in \mathbb{R}^{m \times n}$ serta vektor translasi konstan $\mathbf{b} \in \mathbb{R}^m$, maka vektor hasil transformasi affine $\mathbf{f} = A\mathbf{u} + \mathbf{b}$ terdistribusi secara Gaussian multivariat berdimensi m :*

$$\mathbf{f} = A\mathbf{u} + \mathbf{b} \sim \mathcal{N}(A\mu_u + \mathbf{b}, A\Sigma_u A^T) \quad (1)$$

Karena komputer hanya mampu membangkitkan *noise* independen $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I_{N_*})$, kita memerlukan transformasi affine untuk membentuk korelasi antar-titik. Berdasarkan Teorema 1.1, kita mengalikan *noise* tersebut dengan faktor Cholesky L (di mana $\tilde{K} = LL^T$) dan menambahkan nilai rata-rata $\mathbf{m}_*$. Vektor sampel $\mathbf{f}_* = \mathbf{m}_* + L\mathbf{u}$ yang terbentuk secara eksak memenuhi:

$$\mathbb{E}[\mathbf{f}_*] = \mathbf{m}_* + L\mathbb{E}[\mathbf{u}] = \mathbf{m}_* + L(\mathbf{0}) = \mathbf{m}_* \quad (2)$$

$$\text{cov}(\mathbf{f}_*) = \mathbb{E}[(L\mathbf{u})(L\mathbf{u})^T] = L\mathbb{E}[\mathbf{u}\mathbf{u}^T]L^T = LI_{N_*}L^T = LL^T = \tilde{K} \approx K(X_*, X_*) \quad (3)$$

sehingga $\mathbf{f}_* \sim \mathcal{N}(\mathbf{m}_*, K)$.

1.1 Algoritma Komputasi Sampling GP

Sampling GP diimplementasikan melalui tahapan berikut:

1. **Evaluasi & Regularisasi Matriks Kovariansi:** Hitung matriks $K = K(X_*, X_*)$ dan tambahkan nilai *jitter* diagonal $\epsilon \approx 10^{-6}$ untuk menjamin sifat definit positif terhadap galat numerik:

$$\tilde{K} = K + \epsilon I_{N_*} \quad (4)$$

2. **Faktorisasi Cholesky:** Dekomposisi $\tilde{K}$ menjadi matriks segitiga bawah unik $L \in \mathbb{R}^{N_* \times N_*}$:

$$\tilde{K} = LL^T \quad (5)$$

3. **Generating Random Noise:** Bangkitkan vektor *noise* baku $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, I_{N_*})$. Untuk S kurva sekaligus, gunakan matriks $U \in \mathbb{R}^{N_* \times S}$ dengan $U_{ij} \sim \mathcal{N}(0, 1)$.

4. **Transformasi Affine:** Hitung sampel fungsi melalui:

$$\mathbf{f}_* = \mathbf{m}_* + L\mathbf{u} \quad \left(\text{atau } F = \mathbf{m}_* \mathbf{1}_S^T + LU \text{ untuk } S \text{ sampel} \right) \quad (6)$$

1.2 Sampling Prior versus Posterior

Mekanisme transformasi Cholesky berlaku serupa baik sebelum maupun sesudah mengamati data observasi $(X, \mathbf{y})$:

- **Prior Sampling:** Menggunakan mean $\mathbf{m}_*$ dan matriks kovariansi $K(X_*, X_*)$:

$$\mathbf{f}_* \sim \mathcal{N}(\mathbf{m}_*, K(X_*, X_*)) \implies \mathbf{f}_* = \mathbf{m}_* + L\mathbf{u}, \quad \text{dengan } L = \text{cholesky}(K(X_*, X_*) + \epsilon I_{N_*}) \quad (7)$$

- **Posterior Sampling:** Menggunakan distribusi posterior Gaussian Process Regression (Rasmussen & Williams, 2006):

$$\mathbf{f}_* | X, \mathbf{y}, X_* \sim \mathcal{N}(\bar{\mathbf{f}}_*, \text{cov}(\mathbf{f}_*)) \quad (8)$$

dengan parameter analitik:

$$\bar{\mathbf{f}}_* = K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} \mathbf{y} \quad (9)$$

$$\text{cov}(\mathbf{f}_*) = K(X_*, X_*) - K(X_*, X) \left[K(X, X) + \sigma_n^2 I_N \right]^{-1} K(X, X_*) \quad (10)$$

Sampel fungsi posterior dihitung melalui:

$$\mathbf{f}_{*,\text{post}} = \bar{\mathbf{f}}_* + L_{\text{post}}\mathbf{u}, \quad \text{dengan } L_{\text{post}} = \text{cholesky}(\text{cov}(\mathbf{f}_*) + \epsilon I_{N_*}) \quad (11)$$


2 Eksplorasi Fungsi Kovariansi (Kernel)

2.1 Katalog dan Karakteristik Kernel Baku


Nama Kernel	Formula $k(r)$ / $k(\mathbf{x}, \mathbf{x}')$	Sifat	Hyperparameter
Squared Exponential	$\sigma_f^2 \exp\left(-\frac{r^2}{2l^2}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Exponential ($\nu = 1/2$)	$\sigma_f^2 \exp\left(-\frac{r}{l}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Matérn ($\nu = 3/2$)	$\sigma_f^2 \left(1 + \frac{\sqrt{3}r}{l}\right) \exp\left(-\frac{\sqrt{3}r}{l}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Matérn ($\nu = 5/2$)	$\sigma_f^2 \left(1 + \frac{\sqrt{5}r}{l} + \frac{5r^2}{3l^2}\right) \exp\left(-\frac{\sqrt{5}r}{l}\right)$	Stasioner	$l > 0, \sigma_f^2 > 0$
Rational Quadratic	$\sigma_f^2 \left(1 + \frac{r^2}{2\alpha l^2}\right)^{-\alpha}$	Stasioner	$l > 0, \sigma_f^2 > 0, \alpha > 0$
Linear (Dot Product)	$\sigma_b^2 + \sigma_v^2(\mathbf{x} - c)(\mathbf{x}' - c)$	Non-stasioner	$\sigma_b^2 \geq 0, \sigma_v^2 > 0, c \in \mathbb{R}$

Tabel 1: Katalog fungsi kovariansi standar dari buku teks Rasmussen & Williams (2006).

Karakteristik kelas kernel baku dirangkum pada Tabel 1. Peluruhan nilai kovariansi dan sampel fungsi prior $\mathbf{f} \sim \mathcal{GP}(\mathbf{0}, K)$ disajikan pada Gambar 1 dan Gambar 2. Visualisasi memperlihatkan variasi karakteristik kurva sampel: mulai dari lintasan kasar bergerigi ($\nu = 1/2$), berfluktuasi teratur ($\nu = 3/2, 5/2$), sangat mulus (SE), hingga perilaku non-stasioner (Linear).



Gambar 1: Karakteristik fungsi kovariansi dan sampel fungsi prior untuk kernel Matérn serta Rational Quadratic.




Gambar 2: Sampel fungsi prior $\mathbf{f} \sim \mathcal{GP}(0, K)$ untuk enam kelas kernel baku.

Pengaruh fisis dan geometris variasi hyperparameter (Gambar 3) dirangkum sebagai berikut (Rasmussen & Williams, 2006):

- **Lengthscale** (l) (Gambar 3a): Mengatur jangkauan korelasi horizontal; l kecil menghasilkan fluktuasi cepat, sedangkan l besar menghasilkan kurva yang lambat bervariasi.
- **Signal Variance** (σ_f^2) (Gambar 3b): Mengatur skala amplitudo vertikal.

- **Parameter ν** : Mengontrol tingkat kehalusan kurva pada kelas Matérn.
- **Scale Mixture (α)** (Gambar 3c): Mengatur variasi multi-skala pada Rational Quadratic.
- **Parameter Linear ($c, \sigma_v^2, \sigma_b^2$)** (Gambar 3d): Mengatur titik tumpu c dan variansi non-stasioner $\text{Var}[f(x)] = \sigma_b^2 + \sigma_v^2(x - c)^2$.



Gambar 3: Pengaruh variasi hyperparameter terhadap karakteristik sampel fungsi prior GP.

2.2 Operasi Aljabar Kernel

Kombinasi kernel dasar menghasilkan fungsi kovariansi baru yang tetap valid dan definit positif (Rasmussen & Williams, 2006):

- **Penjumlahan:** $k(\mathbf{x}, \mathbf{x}') = k_1(\mathbf{x}, \mathbf{x}') + k_2(\mathbf{x}, \mathbf{x}')$
Merepresentasikan superposisi proses independen $f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x})$.
- **Perkalian:** $k(\mathbf{x}, \mathbf{x}') = k_1(\mathbf{x}, \mathbf{x}') \cdot k_2(\mathbf{x}, \mathbf{x}')$
Merepresentasikan interaksi atau modulasi proses $f(\mathbf{x}) = f_1(\mathbf{x}) \cdot f_2(\mathbf{x})$.

Pustaka

- [1] Rasmussen, C. E., & Williams, C. K. (2006). *Gaussian Processes for Machine Learning*. MIT Press, Cambridge, MA.
- [2] Hogg, R. V., McKean, J. W., & Craig, A. T. (2013). *Introduction to Mathematical Statistics* (7th ed.). Pearson, Boston.