SUPLEMEN TEKNIS: DEEP GAUSSIAN PROCESS (DGP)

Konsep "Neuron", Arsitektur Hierarkis, dan Contoh Perhitungan Manual ($N = 3$)

Topik Tugas Akhir: *Image Segmentation with Deep Gaussian Process*
Catatan Diskusi & Panduan Teoretis Bimbingan 06

20 Oktober 2026

Ringkasan

Dokumen ringkas ini merangkum esensi komputasi dan pemodelan *Deep Gaussian Process* (DGP). Pembahasan difokuskan pada tiga pilar utama: (1) interpretasi konsep "banyak neuron" pada DGP (teorema Neal lebar tak terhingga vs dimensi representasi laten terhitung), (2) diagram alur arsitektur propagasi hierarkis dua lapisan ($L = 2$) dengan trik reparameterisasi, serta (3) simulasi perhitungan matriks manual menggunakan angka *dummy* konkret ($N = 3$) pada titik interpolasi baru ($x_* = 3.0$). Ditunjukkan secara analitik bagaimana ketidakpastian *hidden layer* merambat melalui *Law of Total Variance* menuju luaran akhir.

---

1 Konsep "Banyak Neuron" pada Deep Gaussian Process

Dalam *Deep Neural Network* (DNN), neuron adalah unit komputasi skalar berbobot: $h_j = \sigma(\sum_i W_{ji}x_i + b_j)$. Ketika beralih ke *Deep Gaussian Process* (DGP), konsep "neuron" dipahami melalui **dua sudut pandang**:

1. **Sudut Pandang Teoretis (Teorema Neal, 1995) → Neuron Tak Terhingga (∞)**:
   Jika bobot dan bias neural network berprior Gaussian independen $W_{ji} \sim \mathcal{N}(0, \sigma_w^2)$ diekspansi lebarnya menuju tak berhingga ($M \to \infty$), distribusi fungsi jaringan tersebut berkonvergensi eksak ke proses Gaussian:
   $$\lim_{M\to\infty} f_{\text{NN}}(\mathbf{x}) \equiv \mathcal{GP}\left(0,\ k(\mathbf{x}, \mathbf{x}')\right) \tag{1}$$
   Artinya, **setiap satu fungsi GP secara inheren memuat kapasitas representasi ∞ neuron berbobot acak** di ruang bobot (*weight space*).

2. **Sudut Pandang Arsitektural Praktis → Dimensi Laten Terhitung (D_ℓ)**:
   Yang diatur oleh arsitek DGP pada setiap *hidden layer* adalah **dimensi representasi laten** D_ℓ (jumlah fungsi laten / variabel laten). Jika $D_\ell = 1$, terdapat 1 fungsi laten skalar $h \in \mathbb{R}$. Jika $D_\ell = 2$ atau $D_\ell = 16$, terdapat beberapa dimensi laten independen:
   $$\mathbf{h}^{(\ell)} = \begin{bmatrix} h_1^{(\ell)} \\ \vdots \\ h_{D_\ell}^{(\ell)} \end{bmatrix}, \quad h_d^{(\ell)} \sim \mathcal{GP}\left(0,\ k_d^{(\ell)}\right), \quad d = 1, \ldots, D_\ell \tag{2}$$
   Keunggulan *kernel trick*: berapapun jumlah dimensi laten D_ℓ, **dimensi matriks kovariansi $K^{(\ell)}$ tetap berukuran** $[N \times N]$ (hanya bergantung pada jumlah data N, bukan jumlah dimensi laten).

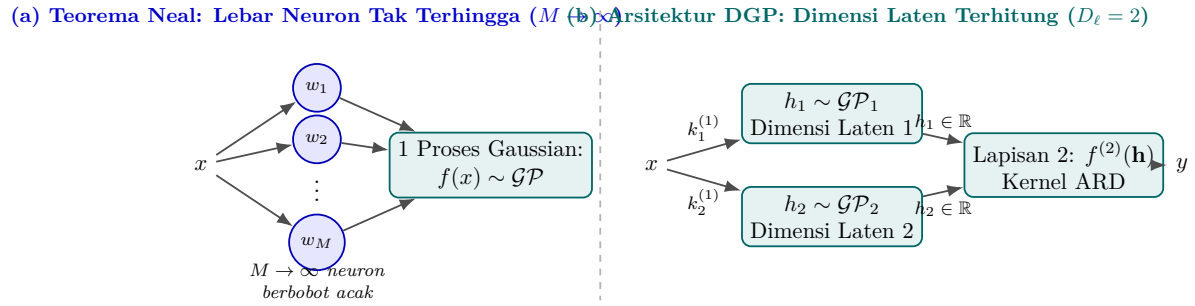
2 Arsitektur Propagasi Hierarkis DGP ($L = 2$)

Diberikan DGP dua lapisan: masukan $x \in \mathbb{R}$, *hidden layer* dengan variabel laten $h \in \mathbb{R}$ ($D_1 = 1$), dan luaran target $y \in \mathbb{R}$.

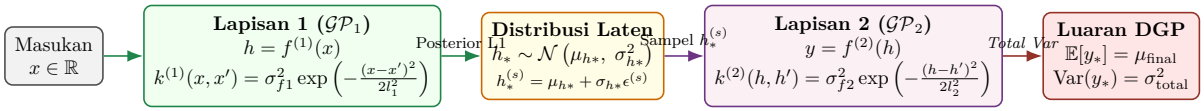
2.1 Tantangan Non-linearitas dan Reparameterization Trick

Karena luaran Lapisan 1 berupa variabel acak $h_* \sim \mathcal{N}(\mu_{h*}, \sigma_{h*}^2)$, integrasi eksak melalui fungsi kernel non-linier $k^{(2)}(h_*, h_i)$ bersifat intraktabel (*intractable*). Salimbeni & Deisenroth (2017) mengatasi kendala ini menggunakan **Trik Reparameterisasi Monte Carlo**:

$$h_*^{(s)} = \mu_{h*} + \sigma_{h*} \cdot \epsilon^{(s)}, \quad \epsilon^{(s)} \sim \mathcal{N}(0, 1), \quad s = 1, \ldots, S \tag{3}$$



Gambar 1: Ilustrasi dualitas "neuron" pada DGP: (a) Konvergensi teoretis jaringan berlebar tak terhingga menuju satu proses Gaussian, dan (b) Struktur arsitektural praktis DGP dengan $D_\ell = 2$ dimensi laten terhitung (dua fungsi laten independen).



Gambar 2: Alur propagasi ketidakpastian DGP: *Hidden layer* menghasilkan distribusi acak h_* yang disampel melalui trik reparameterisasi dan dialirkan menuju fungsi kernel Lapisan 2.

2.2 Hukum Variansi Total (Law of Total Variance)

Variansi akhir DGP diurai secara elegan menjadi dua komponen:

$$\text{Var}(y_*) = \underbrace{\mathbb{E}_{h_*}\left[\text{Var}(y_* \mid h_*)\right]}_{\text{Ketidakpastian Lokal Lapisan 2}} + \underbrace{\text{Var}_{h_*}\left(\mathbb{E}[y_* \mid h_*]\right)}_{\text{Ketidakpastian Merambat dari Lapisan 1!}} \tag{4}$$

3 Contoh Perhitungan Numerik Lengkap ($N = 3, N_* = 1$)

Konfigurasi Masalah:

- 3 Titik Data Latih: $(x_1, y_1) = (1.0, 2.0)$, $(x_2, y_2) = (2.0, 1.0)$, $(x_3, y_3) = (4.0, 3.0)$.
- Representasi Laten Latih: $\mathbf{h} = [h_1, h_2, h_3]^T = [0.5,\ 1.2,\ 2.8]^T$.
- Titik Uji Celah Interpolasi: $x_* = 3.0$ (tidak memiliki data observasi).
- Parameter Kernel: $\sigma_{f1}^2 = \sigma_{f2}^2 = 1.0$, $l_1 = l_2 = 1.0$, $\sigma_{n1}^2 = \sigma_{n2}^2 = 0.01$.

3.1 Langkah 1: Pelatihan Lapisan 1 ($X \to \mathbf{h}$)

Fungsi kernel RBF Lapisan 1 didefinisikan sebagai $k^{(1)}(x_i, x_j) = \sigma_{f1}^2 \exp\left(-\frac{(x_i - x_j)^2}{2l_1^2}\right)$. Dengan parameter $\sigma_{f1}^2 = 1.0$ dan $l_1 = 1.0$, setiap elemen kovariansi antar data masukan dihitung secara eksplisit:

$$k^{(1)}(x_1, x_1) = \exp\left(-\frac{(1.0 - 1.0)^2}{2(1.0)^2}\right) = \exp(0) = 1.0000$$

$$k^{(1)}(x_1, x_2) = \exp\left(-\frac{(1.0 - 2.0)^2}{2(1.0)^2}\right) = \exp\left(-\frac{(-1.0)^2}{2}\right) = \exp(-0.5) \approx 0.6065$$

$$k^{(1)}(x_1, x_3) = \exp\left(-\frac{(1.0 - 4.0)^2}{2(1.0)^2}\right) = \exp\left(-\frac{(-3.0)^2}{2}\right) = \exp(-4.5) \approx 0.0111$$

$$k^{(1)}(x_2, x_2) = \exp(0) = 1.0000$$

$$k^{(1)}(x_2, x_3) = \exp\left(-\frac{(2.0 - 4.0)^2}{2(1.0)^2}\right) = \exp\left(-\frac{(-2.0)^2}{2}\right) = \exp(-2.0) \approx 0.1353$$

$$k^{(1)}(x_3, x_3) = \exp(0) = 1.0000$$

Matriks kovariansi data latih $K^{(1)}$ ditambahkan variansi derau observasi $\sigma_{n1}^2 I = 0.01I$, menghasilkan matriks kovariansi $K_y^{(1)}$ dan inversnya:

$$K_y^{(1)} = K^{(1)} + \sigma_{n1}^2 I = \begin{bmatrix} 1.0000 & 0.6065 & 0.0111 \\ 0.6065 & 1.0000 & 0.1353 \\ 0.0111 & 0.1353 & 1.0000 \end{bmatrix} + 0.01I$$

$$= \begin{bmatrix} 1.0100 & 0.6065 & 0.0111 \\ 0.6065 & 1.0100 & 0.1353 \\ 0.0111 & 0.1353 & 1.0100 \end{bmatrix} \tag{5}$$

$$(K_y^{(1)})^{-1} = \begin{bmatrix} 1.5606 & -0.9519 & 0.1104 \\ -0.9519 & 1.5889 & -0.2024 \\ 0.1104 & -0.2024 & 1.0160 \end{bmatrix} \tag{6}$$

Vektor bobot dual Lapisan 1 diperoleh dari perkalian matriks invers $(K_y^{(1)})^{-1}$ dengan target representasi laten latih $\mathbf{h} = [0.5, 1.2, 2.8]^T$:

$$\boldsymbol{\alpha}^{(1)} = (K_y^{(1)})^{-1}\mathbf{h} = \begin{bmatrix} 1.5606 & -0.9519 & 0.1104 \\ -0.9519 & 1.5889 & -0.2024 \\ 0.1104 & -0.2024 & 1.0160 \end{bmatrix} \begin{bmatrix} 0.5 \\ 1.2 \\ 2.8 \end{bmatrix}$$

$$= \begin{bmatrix} (1.5606 \times 0.5) + (-0.9519 \times 1.2) + (0.1104 \times 2.8) \\ (-0.9519 \times 0.5) + (1.5889 \times 1.2) + (-0.2024 \times 2.8) \\ (0.1104 \times 0.5) + (-0.2024 \times 1.2) + (1.0160 \times 2.8) \end{bmatrix}$$

$$= \begin{bmatrix} 0.7803 - 1.1423 + 0.3091 \\ -0.4760 + 1.9067 - 0.5667 \\ 0.0552 - 0.2429 + 2.8448 \end{bmatrix} = \begin{bmatrix} \mathbf{-0.0530} \\ \mathbf{0.8639} \\ \mathbf{2.6571} \end{bmatrix} \tag{7}$$

3.2 Langkah 2: Pelatihan Lapisan 2 ($\mathbf{h} \to \mathbf{y}$)

Pada Lapisan 2, fungsi kernel $k^{(2)}(h_i, h_j) = \sigma_{f2}^2 \exp\left(-\frac{(h_i - h_j)^2}{2l_2^2}\right)$ mengukur jarak kemiripan **antar representasi laten** $\mathbf{h} = [0.5, 1.2, 2.8]^T$:

$$k^{(2)}(h_1, h_2) = \exp\left(-\frac{(0.5 - 1.2)^2}{2(1.0)^2}\right) = \exp\left(-\frac{(-0.7)^2}{2}\right) = \exp(-0.2450) \approx 0.7827$$

$$k^{(2)}(h_1, h_3) = \exp\left(-\frac{(0.5 - 2.8)^2}{2(1.0)^2}\right) = \exp\left(-\frac{(-2.3)^2}{2}\right) = \exp(-2.6450) \approx 0.0710$$

$$k^{(2)}(h_2, h_3) = \exp\left(-\frac{(1.2 - 2.8)^2}{2(1.0)^2}\right) = \exp\left(-\frac{(-1.6)^2}{2}\right) = \exp(-1.2800) \approx 0.2780$$

Matriks kovariansi Lapisan 2 $K_y^{(2)}$ dan inversnya:

$$K_y^{(2)} = K^{(2)} + \sigma_{n2}^2 I = \begin{bmatrix} 1.0000 & 0.7827 & 0.0710 \\ 0.7827 & 1.0000 & 0.2780 \\ 0.0710 & 0.2780 & 1.0000 \end{bmatrix} + 0.01I$$

$$= \begin{bmatrix} 1.0100 & 0.7827 & 0.0710 \\ 0.7827 & 1.0100 & 0.2780 \\ 0.0710 & 0.2780 & 1.0100 \end{bmatrix} \tag{8}$$

$$(K_y^{(2)})^{-1} = \begin{bmatrix} 2.6577 & -2.1388 & 0.4014 \\ -2.1388 & 2.7667 & -0.6111 \\ 0.4014 & -0.6111 & 1.1495 \end{bmatrix} \tag{9}$$

Vektor bobot dual Lapisan 2 dihitung dari target luaran $\mathbf{y} = [2.0, 1.0, 3.0]^T$:

$$\begin{aligned}\boldsymbol{\alpha}^{(2)} = (K_y^{(2)})^{-1}\mathbf{y} &= \begin{bmatrix} 2.6577 & -2.1388 & 0.4014 \\ -2.1388 & 2.7667 & -0.6111 \\ 0.4014 & -0.6111 & 1.1495 \end{bmatrix} \begin{bmatrix} 2.0 \\ 1.0 \\ 3.0 \end{bmatrix} \\ &= \begin{bmatrix} (2.6577 \times 2.0) + (-2.1388 \times 1.0) + (0.4014 \times 3.0) \\ (-2.1388 \times 2.0) + (2.7667 \times 1.0) + (-0.6111 \times 3.0) \\ (0.4014 \times 2.0) + (-0.6111 \times 1.0) + (1.1495 \times 3.0) \end{bmatrix} \\ &= \begin{bmatrix} 5.3154 - 2.1388 + 1.2042 \\ -4.2776 + 2.7667 - 1.8333 \\ 0.8028 - 0.6111 + 3.4485 \end{bmatrix} = \begin{bmatrix} \mathbf{4.3212} \\ \mathbf{-3.3462} \\ \mathbf{3.5877} \end{bmatrix} \end{aligned} \tag{10}$$

3.3 Langkah 3: Evaluasi Titik Interpolasi Baru ($x_* = 3.0$)

A. Propagasi Maju Lapisan 1 ($x_* \to h_*$): Vektor kemiripan titik uji $x_* = 3.0$ terhadap seluruh data latih masukan dihitung secara eksplisit pada setiap elemennya:

$$\begin{aligned}\mathbf{k}_*^{(1)} &= \begin{bmatrix} k^{(1)}(x_1, x_*) \\ k^{(1)}(x_2, x_*) \\ k^{(1)}(x_3, x_*) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(x_1 - x_*)^2}{2l_1^2}\right) \\ \exp\left(-\frac{(x_2 - x_*)^2}{2l_1^2}\right) \\ \exp\left(-\frac{(x_3 - x_*)^2}{2l_1^2}\right) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(1.0-3.0)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(2.0-3.0)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(4.0-3.0)^2}{2(1.0)^2}\right) \end{bmatrix} \\ &= \begin{bmatrix} \exp\left(-\frac{(-2.0)^2}{2}\right) \\ \exp\left(-\frac{(-1.0)^2}{2}\right) \\ \exp\left(-\frac{(1.0)^2}{2}\right) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{4.0}{2}\right) \\ \exp\left(-\frac{1.0}{2}\right) \\ \exp\left(-\frac{1.0}{2}\right) \end{bmatrix} = \begin{bmatrix} \exp(-2.0) \\ \exp(-0.5) \\ \exp(-0.5) \end{bmatrix} = \begin{bmatrix} \mathbf{0.1353} \\ \mathbf{0.6065} \\ \mathbf{0.6065} \end{bmatrix} \end{aligned} \tag{11}$$

Nilai ekspektasi (mean) variabel laten posterior μ_{h*} di $x_* = 3.0$ diperoleh dari hasil kali dalam $\mathbf{k}_*^{(1)T}\boldsymbol{\alpha}^{(1)}$:

$$\begin{aligned}\mu_{h*} = \mathbf{k}_*^{(1)T}\boldsymbol{\alpha}^{(1)} &= \begin{bmatrix} 0.1353 & 0.6065 & 0.6065 \end{bmatrix} \begin{bmatrix} -0.0530 \\ 0.8639 \\ 2.6571 \end{bmatrix} \\ &= (0.1353 \times -0.0530) + (0.6065 \times 0.8639) + (0.6065 \times 2.6571) \\ &= -0.0072 + 0.5239 + 1.6117 = \mathbf{2.1284} \end{aligned} \tag{12}$$

Untuk menghitung variansi laten, pertama-tama kita evaluasi vektor perantara $\mathbf{v}^{(1)} = (K_y^{(1)})^{-1}\mathbf{k}_*^{(1)}$:

$$\begin{aligned}\mathbf{v}^{(1)} = (K_y^{(1)})^{-1}\mathbf{k}_*^{(1)} &= \begin{bmatrix} 1.5606 & -0.9519 & 0.1104 \\ -0.9519 & 1.5889 & -0.2024 \\ 0.1104 & -0.2024 & 1.0160 \end{bmatrix} \begin{bmatrix} 0.1353 \\ 0.6065 \\ 0.6065 \end{bmatrix} \\ &= \begin{bmatrix} (1.5606 \times 0.1353) + (-0.9519 \times 0.6065) + (0.1104 \times 0.6065) \\ (-0.9519 \times 0.1353) + (1.5889 \times 0.6065) + (-0.2024 \times 0.6065) \\ (0.1104 \times 0.1353) + (-0.2024 \times 0.6065) + (1.0160 \times 0.6065) \end{bmatrix} = \begin{bmatrix} -0.2995 \\ 0.7126 \\ 0.5080 \end{bmatrix} \end{aligned} \tag{13}$$

Kemudian, besarnya reduksi variansi prior oleh data observasi latih dihitung melalui bentuk kuadratik:

$$\begin{aligned}\mathbf{k}_*^{(1)T}(K_y^{(1)})^{-1}\mathbf{k}_*^{(1)} = \mathbf{k}_*^{(1)T}\mathbf{v}^{(1)} &= \begin{bmatrix} 0.1353 & 0.6065 & 0.6065 \end{bmatrix} \begin{bmatrix} -0.2995 \\ 0.7126 \\ 0.5080 \end{bmatrix} \\ &= (0.1353 \times -0.2995) + (0.6065 \times 0.7126) + (0.6065 \times 0.5080) \\ &= -0.0405 + 0.4322 + 0.3081 = \mathbf{0.6998} \end{aligned} \tag{14}$$

Dengan variansi prior $k^{(1)}(x_*, x_*) = \sigma_{f1}^2 \exp(0) = 1.0000$, diperoleh variansi dan standar deviasi laten posterior:

$$\sigma_{h*}^2 = k^{(1)}(x_*, x_*) - \mathbf{k}_*^{(1)T}(K_y^{(1)})^{-1}\mathbf{k}_*^{(1)} = 1.0000 - 0.6998 = \mathbf{0.3002} \tag{15}$$

$$\sigma_{h*} = \sqrt{0.3002} = \mathbf{0.5479} \tag{16}$$

Luaran Lapisan 1 berupa distribusi Gaussian kontinu: $h_* \sim \mathcal{N}\left(\mu_{h*} = 2.1284,\ \sigma^2_{h*} = 0.3002\right)$.

B. Reparameterization Sampling: Untuk merambatkan distribusi kontinu h_* ke kernel non-linier Lapisan 2, kita mengambil $S = 3$ sampel representatif menggunakan trik reparameterisasi $h_*^{(s)} = \mu_{h*} + \sigma_{h*} \cdot \epsilon^{(s)}$:

$$\text{Sampel 1 } (\epsilon^{(1)} = 0): \quad h_*^{(1)} = 2.1284 + (0.5479 \times 0) = \mathbf{2.1284} \quad \text{(Nilai mean representasi)} \tag{17}$$

$$\text{Sampel 2 } (\epsilon^{(2)} = +1): \quad h_*^{(2)} = 2.1284 + (0.5479 \times 1.0) = \mathbf{2.6763} \quad \text{(Mendekati data laten } h_3 = 2.8) \tag{18}$$

$$\text{Sampel 3 } (\epsilon^{(3)} = -1): \quad h_*^{(3)} = 2.1284 - (0.5479 \times 1.0) = \mathbf{1.5805} \quad \text{(Mendekati data laten } h_2 = 1.2) \tag{19}$$

C. Propagasi Maju Lapisan 2 untuk Setiap Sampel ($h_*^{(s)} \to y_*^{(s)}$): Untuk masing-masing sampel $h_*^{(s)}$, vektor kemiripan $\mathbf{k}_*^{(2)(s)}$ dievaluasi terhadap seluruh representasi laten latih $[h_1, h_2, h_3] = [0.5, 1.2, 2.8]$:

1. **Evaluasi Sampel 1 ($h_*^{(1)} = 2.1284$):**

$$\mathbf{k}_*^{(2)(1)} = \begin{bmatrix} k^{(2)}(h_1, h_*^{(1)}) \\ k^{(2)}(h_2, h_*^{(1)}) \\ k^{(2)}(h_3, h_*^{(1)}) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(0.5-2.1284)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(1.2-2.1284)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(2.8-2.1284)^2}{2(1.0)^2}\right) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(-1.6284)^2}{2}\right) \\ \exp\left(-\frac{(-0.9284)^2}{2}\right) \\ \exp\left(-\frac{(0.6716)^2}{2}\right) \end{bmatrix}$$
$$= \begin{bmatrix} \exp(-1.3259) \\ \exp(-0.4310) \\ \exp(-0.2255) \end{bmatrix} = \begin{bmatrix} \mathbf{0.2656} \\ \mathbf{0.6499} \\ \mathbf{0.7981} \end{bmatrix} \tag{20}$$

Prediksi mean kondisional $\mu_{y*}^{(1)}$:

$$\mu_{y*}^{(1)} = \mathbf{k}_*^{(2)(1)T} \boldsymbol{\alpha}^{(2)} = \begin{bmatrix} 0.2656 & 0.6499 & 0.7981 \end{bmatrix} \begin{bmatrix} 4.3212 \\ -3.3462 \\ 3.5877 \end{bmatrix}$$
$$= (0.2656 \times 4.3212) + (0.6499 \times -3.3462) + (0.7981 \times 3.5877)$$
$$= 1.1477 - 2.1747 + 2.8633 = \mathbf{1.8363} \tag{21}$$

Vektor perantara $\mathbf{v}^{(2)(1)} = (K_y^{(2)})^{-1} \mathbf{k}_*^{(2)(1)}$ dan variansi lokal $\sigma_{y*}^{2(1)}$:

$$\mathbf{v}^{(2)(1)} = \begin{bmatrix} 2.6577 & -2.1388 & 0.4014 \\ -2.1388 & 2.7667 & -0.6111 \\ 0.4014 & -0.6111 & 1.1495 \end{bmatrix} \begin{bmatrix} 0.2656 \\ 0.6499 \\ 0.7981 \end{bmatrix} = \begin{bmatrix} -0.3639 \\ 0.7431 \\ 0.6276 \end{bmatrix} \tag{22}$$

$$\sigma_{y*}^{2(1)} = k^{(2)}(h_*^{(1)}, h_*^{(1)}) - \mathbf{k}_*^{(2)(1)T} \mathbf{v}^{(2)(1)}$$
$$= 1.0 - ((0.2656 \times -0.3639) + (0.6499 \times 0.7431) + (0.7981 \times 0.6276))$$
$$= 1.0 - (-0.0967 + 0.4829 + 0.5009) = 1.0 - 0.8820 = \mathbf{0.1180} \tag{23}$$

2. **Evaluasi Sampel 2 ($h_*^{(2)} = 2.6763$):**

$$\mathbf{k}_*^{(2)(2)} = \begin{bmatrix} \exp\left(-\frac{(0.5-2.6763)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(1.2-2.6763)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(2.8-2.6763)^2}{2(1.0)^2}\right) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(-2.1763)^2}{2}\right) \\ \exp\left(-\frac{(-1.4763)^2}{2}\right) \\ \exp\left(-\frac{(0.1237)^2}{2}\right) \end{bmatrix} = \begin{bmatrix} \exp(-2.3681) \\ \exp(-1.0897) \\ \exp(-0.0077) \end{bmatrix} = \begin{bmatrix} \mathbf{0.0936} \\ \mathbf{0.3363} \\ \mathbf{0.9924} \end{bmatrix} \tag{24}$$

Prediksi mean kondisional $\mu_{y*}^{(2)}$:

$$\mu_{y*}^{(2)} = (0.0936 \times 4.3212) + (0.3363 \times -3.3462) + (0.9924 \times 3.5877)$$
$$= 0.4045 - 1.1253 + 3.5604 = \mathbf{2.8397} \tag{25}$$

Vektor perantara $\mathbf{v}^{(2)(2)} = [-0.0726,\ 0.1245,\ 0.9729]^T$ dan variansi lokal:

$$\sigma_{y*}^{2(2)} = 1.0 - \mathbf{k}_*^{(2)(2)T}\mathbf{v}^{(2)(2)} = 1.0 - (-0.0068 + 0.0419 + 0.9655) = 1.0 - 0.9814 = \mathbf{0.0186} \quad (26)$$

(Perhatikan: Karena representasi laten $h_*^{(2)} = 2.6763$ sangat mendekati titik latih $h_3 = 2.8$, prediksi mean $\mu_{y*}^{(2)}$ melonjak menuju target $y_3 = 3.0$ dengan kepastian tinggi / variansi sangat kecil $\sigma_{y*}^{2(2)} = 0.0186$).

3. **Evaluasi Sampel 3 ($h_*^{(3)} = 1.5805$):**

$$\mathbf{k}_*^{(2)(3)} = \begin{bmatrix} \exp\left(-\frac{(0.5-1.5805)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(1.2-1.5805)^2}{2(1.0)^2}\right) \\ \exp\left(-\frac{(2.8-1.5805)^2}{2(1.0)^2}\right) \end{bmatrix} = \begin{bmatrix} \exp\left(-\frac{(-1.0805)^2}{2}\right) \\ \exp\left(-\frac{(-0.3805)^2}{2}\right) \\ \exp\left(-\frac{(1.2195)^2}{2}\right) \end{bmatrix} = \begin{bmatrix} \exp(-0.5837) \\ \exp(-0.0724) \\ \exp(-0.7436) \end{bmatrix} = \begin{bmatrix} \mathbf{0.5578} \\ \mathbf{0.9302} \\ \mathbf{0.4754} \end{bmatrix} \quad (27)$$

Prediksi mean kondisional $\mu_{y*}^{(3)}$:

$$\begin{aligned} \mu_{y*}^{(3)} &= (0.5578 \times 4.3212) + (0.9302 \times -3.3462) + (0.4754 \times 3.5877) \\ &= 2.4104 - 3.1126 + 1.7056 = \mathbf{1.0034} \end{aligned} \quad (28)$$

Vektor perantara $\mathbf{v}^{(2)(3)} = [-0.3117,\ 1.0924,\ 0.2023]^T$ dan variansi lokal:

$$\sigma_{y*}^{2(3)} = 1.0 - \mathbf{k}_*^{(2)(3)T}\mathbf{v}^{(2)(3)} = 1.0 - (-0.1739 + 1.0162 + 0.0962) = 1.0 - 0.9519 = \mathbf{0.0481} \quad (29)$$

(Perhatikan: Karena $h_*^{(3)} = 1.5805$ sangat mendekati $h_2 = 1.2$, prediksi mean $\mu_{y*}^{(3)}$ bergeser mendekati target $y_2 = 1.0$).

D. Agregasi Luaran via Hukum Variansi Total: Rata-rata prediksi luaran DGP dari seluruh lintasan Monte Carlo:

$$\mu_{\text{final}} = \frac{1}{3}\sum_{s=1}^{3} \mu_{y*}^{(s)} = \frac{1.8363 + 2.8397 + 1.0034}{3} = \frac{5.6794}{3} = \mathbf{1.8931} \quad (30)$$

Pemisahan analitis dua komponen variansi total berdasarkan Hukum Variansi Total:

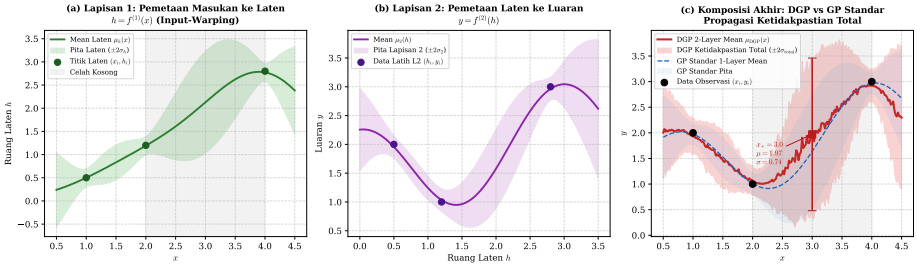
$$\mathbb{E}_{h_*}[\text{Var}(y_* \mid h_*)] = \frac{\sigma_{y*}^{2(1)} + \sigma_{y*}^{2(2)} + \sigma_{y*}^{2(3)}}{3} = \frac{0.1180 + 0.0186 + 0.0481}{3} = \mathbf{0.0616} \quad \text{(Variansi lokal L2)} \quad (31)$$

$$\begin{aligned} \text{Var}_{h_*}(\mathbb{E}[y_* \mid h_*]) &= \frac{1}{3}\sum_{s=1}^{3}\left(\mu_{y*}^{(s)} - \mu_{\text{final}}\right)^2 = \frac{(-0.0568)^2 + (0.9466)^2 + (-0.8897)^2}{3} \\ &= \frac{0.003226 + 0.896052 + 0.791566}{3} = \frac{1.690844}{3} = \mathbf{0.5636} \quad \text{(Variansi merambat L1)} \end{aligned} \quad (32)$$

Variansi total akhir, standar deviasi gabungan, serta interval keyakinan 95%:

$$\sigma_{\text{total}}^2 = \mathbb{E}[\sigma_y^2] + \text{Var}(\mu_y) = 0.0616 + 0.5636 = \mathbf{0.6252} \implies \sigma_{\text{total}} = \sqrt{0.6252} = \mathbf{0.7907} \quad (33)$$

$$\text{IK } 95\% : \quad [1.8931 \pm 2(0.7907)] = [1.8931 \pm 1.5814] = [\mathbf{0.3117},\ \mathbf{3.4745}] \quad (34)$$



Gambar 3: Visualisasi numerik DGP 2-Lapisan: (a) Pemetaan $x \to h$ (*input-warping*), (b) Pemetaan laten ke luaran $h \to y$, dan (c) Kurva akhir DGP dengan penggelembungan pita variansi di wilayah celah data kosong ($x_* = 3.0$).

4 Perbandingan dengan GP Standar dan Relevansi Tugas Akhir

Tabel 1: Perbandingan Metrik Prediksi pada Titik Interpolasi Celah ($x_* = 3.0$).

Parameter Evaluasi	**GP Standar (1-Lapis)**	**DGP (2-Lapis)**	**Makna Fisis & Teoretis**
Prediksi Mean (μ_*)	1.6388	**1.8931**	Mengakomodasi distorsi spasial non-stasioner
Variansi Lokal Luaran	0.3002	0.0616	Ketidakpastian kondisional Lapisan 2
Variansi Merambat (L_1)	0	**0.5636**	Fluktuasi fitur laten merambat ke luaran
Variansi Total (σ_*^2)	0.3002	**0.6252**	Menggelembung 2x lipat (lebih realistis)
Standar Deviasi (σ_*)	0.5479	**0.7907**	Estimasi ketidakpastian berjenjang yang jujur

4.1 Analisis Komparatif: Mengapa Variansi DGP Membengkak?

Dari perbandingan numerik pada Tabel 1, terlihat perbedaan fundamental antara GP standar dan DGP:

1. **Efek Distorsi Spasial (*Input Warping*)**: Prediksi mean DGP bergeser dari 1.6388 ke **1.8931**. Hal ini terjadi karena Lapisan 1 memetakan masukan $x_* = 3.0$ ke ruang laten dengan mean $\mu_{h*} = 2.1284$, yang secara relatif lebih condong mendekati titik latih $h_3 = 2.8$ dibandingkan posisi x_* terhadap x_3 pada ruang masukan asli.

2. **Penjumlahan Variansi Berjenjang**: Variansi total DGP menggelembung menjadi **0.6252** (dua kali lipat GP standar 0.3002). Pada GP standar, ketidakpastian diasumsikan stasioner dan hanya fungsi dari jarak Euclidean masukan. Pada DGP, ketidakpastian dipecah menjadi dua: ketidakpastian kondisional Lapisan 2 (0.0616) dan ketidakpastian merambat dari fluktuasi representasi laten Lapisan 1 (**0.5636**). Komponen kedua inilah yang mendominasi dan mencegah model menderita *overconfidence*.

3. **Sifat Non-Gaussian Luaran**: Secara teoretis, distribusi marginal luaran DGP adalah campuran tak hingga (*infinite mixture*):

$$p(y_* \mid x_*, \mathcal{D}) = \int p\left(y_* \mid h_*, \mathcal{D}^{(2)}\right) p\left(h_* \mid x_*, \mathcal{D}^{(1)}\right) dh_* \tag{35}$$

   Integral ini menghasilkan distribusi posterior non-Gaussian yang mampu menangkap asimetri dan multimodalitas pada data kompleks.

4.2 Implikasi Metodologis untuk Tugas Akhir: *Image Segmentation with DGP*

Pada tugas akhir segmentasi citra, arsitektur DGP memberikan keunggulan metodologis yang signifikan:

- **Ekstraksi Fitur Probabilistik**: *Hidden layer* DGP bertindak sebagai ruang representasi fitur laten spasial. Jika GP standar terikat pada kernel stasioner kaku, DGP mampu meregangkan ruang laten di area transisi tajam dan merapatkannya di wilayah homogen.

- **Estimasi Batas Segmen Terkalibrasi**: Wilayah paling rawan galat pada segmentasi citra adalah piksel perbatasan antar-objek (*boundary edges*). Di zona ambigu ini, komponen variansi laten merambat $\mathrm{Var}_{h_*}(\mathbb{E}[y_* \mid h_*])$ otomatis melonjak tinggi. Hal ini menghasilkan pita keyakinan yang lebar pada batas kontur objek, memberikan informasi ketidakpastian yang jujur bagi praktisi tanpa menderita prediksi yang keliru namun berkeyakinan tinggi (*overconfident misclassification*).