SUPLEMEN TEKNIS: DEEP GAUSSIAN PROCESS (DGP)

Konsep "Neuron", Arsitektur Hierarkis, dan Contoh Perhitungan Manual ($N = 3$)

Topik Tugas Akhir: *Image Segmentation with Deep Gaussian Process*
Catatan Diskusi & Panduan Teoretis Bimbingan 06

20 Oktober 2026

Ringkasan

Dokumen ringkas ini merangkum esensi komputasi dan pemodelan *Deep Gaussian Process* (DGP). Pembahasan difokuskan pada tiga pilar utama: (1) interpretasi konsep "banyak neuron" pada DGP (teorema Neal lebar tak terhingga vs dimensi representasi laten terhitung), (2) diagram alur arsitektur propagasi hierarkis dua lapisan ($L = 2$) dengan trik reparameterisasi, serta (3) simulasi perhitungan matriks manual menggunakan angka *dummy* konkret ($N = 3$) pada titik interpolasi baru ($x_* = 3.0$). Ditunjukkan secara analitik bagaimana ketidakpastian *hidden layer* merambat melalui *Law of Total Variance* menuju luaran akhir.

---

1 Konsep "Banyak Neuron" pada Deep Gaussian Process

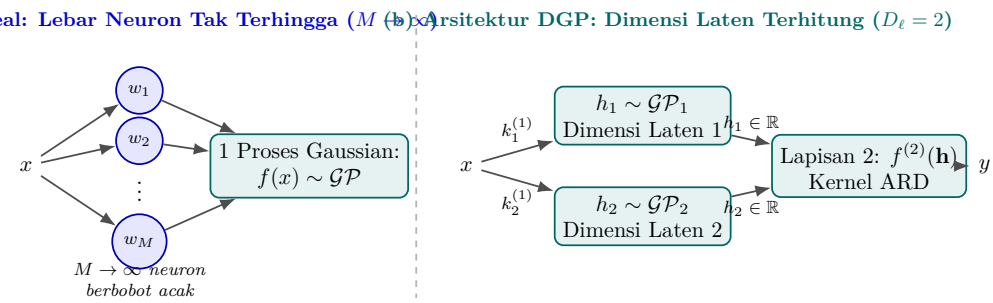
Dalam *Deep Neural Network* (DNN), neuron adalah unit komputasi skalar berbobot: $h_j = \sigma(\sum_i W_{ji}x_i + b_j)$. Ketika beralih ke *Deep Gaussian Process* (DGP), konsep "neuron" dipahami melalui **dua sudut pandang**:

1. **Sudut Pandang Teoretis (Teorema Neal, 1995) → Neuron Tak Terhingga (∞)**:
   Jika bobot dan bias neural network berprior Gaussian independen $W_{ji} \sim \mathcal{N}(0, \sigma_w^2)$ diekspansi lebarnya menuju tak berhingga ($M \to \infty$), distribusi fungsi jaringan tersebut berkonvergensi eksak ke proses Gaussian:
   $$\lim_{M\to\infty} f_{\text{NN}}(\mathbf{x}) \equiv \mathcal{GP}\left(0,\ k(\mathbf{x}, \mathbf{x}')\right) \tag{1}$$
   Artinya, **setiap satu fungsi GP secara inheren memuat kapasitas representasi ∞ neuron berbobot acak** di ruang bobot (*weight space*).

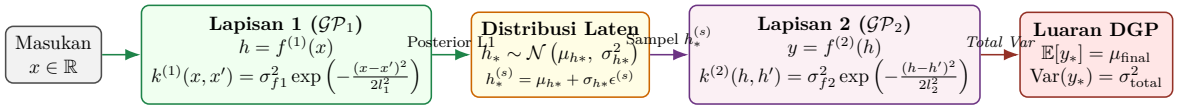
2. **Sudut Pandang Arsitektural Praktis → Dimensi Laten Terhitung (D_ℓ)**:
   Yang diatur oleh arsitek DGP pada setiap *hidden layer* adalah **dimensi representasi laten** D_ℓ (jumlah fungsi laten / variabel laten). Jika $D_\ell = 1$, terdapat 1 fungsi laten skalar $h \in \mathbb{R}$. Jika $D_\ell = 2$ atau $D_\ell = 16$, terdapat beberapa dimensi laten independen:
   $$\mathbf{h}^{(\ell)} = \begin{bmatrix} h_1^{(\ell)} \\ \vdots \\ h_{D_\ell}^{(\ell)} \end{bmatrix}, \quad h_d^{(\ell)} \sim \mathcal{GP}\left(0,\ k_d^{(\ell)}\right), \quad d = 1, \ldots, D_\ell \tag{2}$$
   Keunggulan *kernel trick*: berapapun jumlah dimensi laten D_ℓ, **dimensi matriks kovariansi $K^{(\ell)}$ tetap berukuran** $[N \times N]$ (hanya bergantung pada jumlah data N, bukan jumlah dimensi laten).

2 Arsitektur Propagasi Hierarkis DGP ($L = 2$)

Diberikan DGP dua lapisan: masukan $x \in \mathbb{R}$, *hidden layer* dengan variabel laten $h \in \mathbb{R}$ ($D_1 = 1$), dan luaran target $y \in \mathbb{R}$.



Gambar 1: Ilustrasi dualitas "neuron" pada DGP: (a) Konvergensi teoretis jaringan berlebar tak terhingga menuju satu proses Gaussian, dan (b) Struktur arsitektural praktis DGP dengan $D_\ell = 2$ dimensi laten terhitung (dua fungsi laten independen).



Gambar 2: Alur propagasi ketidakpastian DGP: *Hidden layer* menghasilkan distribusi acak h_* yang disampel melalui trik reparameterisasi dan dialirkan menuju fungsi kernel Lapisan 2.

2.1 Tantangan Non-linearitas dan Reparameterization Trick

Karena luaran Lapisan 1 berupa variabel acak $h_* \sim \mathcal{N}(\mu_{h*}, \sigma_{h*}^2)$, integrasi eksak melalui fungsi kernel non-linier $k^{(2)}(h_*, h_i)$ bersifat intraktabel (*intractable*). Salimbeni & Deisenroth (2017) mengatasi kendala ini menggunakan **Trik Reparameterisasi Monte Carlo**:

$$h_*^{(s)} = \mu_{h*} + \sigma_{h*} \cdot \epsilon^{(s)}, \quad \epsilon^{(s)} \sim \mathcal{N}(0, 1), \quad s = 1, \ldots, S \tag{3}$$

2.2 Hukum Variansi Total (Law of Total Variance)

Variansi akhir DGP diurai secara elegan menjadi dua komponen:

$$\text{Var}(y_*) = \underbrace{\mathbb{E}_{h_*}\left[\text{Var}(y_* \mid h_*)\right]}_{\text{Ketidakpastian Lokal Lapisan 2}} + \underbrace{\text{Var}_{h_*}\left(\mathbb{E}[y_* \mid h_*]\right)}_{\text{Ketidakpastian Merambat dari Lapisan 1!}} \tag{4}$$

3 Contoh Perhitungan Numerik Lengkap ($N = 3, N_* = 1$)

Konfigurasi Masalah:

- 3 Titik Data Latih: $(x_1, y_1) = (1.0, 2.0)$, $(x_2, y_2) = (2.0, 1.0)$, $(x_3, y_3) = (4.0, 3.0)$.
- Representasi Laten Latih: $\mathbf{h} = [h_1, h_2, h_3]^T = [0.5,\ 1.2,\ 2.8]^T$.
- Titik Uji Celah Interpolasi: $x_* = 3.0$ (tidak memiliki data observasi).
- Parameter Kernel: $\sigma_{f1}^2 = \sigma_{f2}^2 = 1.0$, $l_1 = l_2 = 1.0$, $\sigma_{n1}^2 = \sigma_{n2}^2 = 0.01$.

3.1 Langkah 1: Pelatihan Lapisan 1 ($X \to \mathbf{h}$)

Matriks kovariansi masukan $K_y^{(1)} = K(X, X) + \sigma_{n1}^2 I$ dan inversnya:

$$K_y^{(1)} = \begin{bmatrix} 1.0100 & 0.6065 & 0.0111 \\ 0.6065 & 1.0100 & 0.1353 \\ 0.0111 & 0.1353 & 1.0100 \end{bmatrix}, \quad (K_y^{(1)})^{-1} = \begin{bmatrix} 1.5606 & -0.9519 & 0.1104 \\ -0.9519 & 1.5889 & -0.2024 \\ 0.1104 & -0.2024 & 1.0160 \end{bmatrix} \tag{5}$$

Vektor bobot dual Lapisan 1:

$$\boldsymbol{\alpha}^{(1)} = (K_y^{(1)})^{-1}\mathbf{h} = (K_y^{(1)})^{-1}\begin{bmatrix}0.5\\1.2\\2.8\end{bmatrix} = \begin{bmatrix}\mathbf{-0.0530}\\\mathbf{0.8639}\\\mathbf{2.6571}\end{bmatrix} \tag{6}$$

3.2 Langkah 2: Pelatihan Lapisan 2 ($\mathbf{h} \to \mathbf{y}$)

Jarak kernel Lapisan 2 dihitung antar fitur laten $\mathbf{h} = [0.5, 1.2, 2.8]^T$:

- $k^{(2)}(h_1, h_2) = \exp\left(-0.5 \times |0.5 - 1.2|^2\right) = \exp(-0.245) = 0.7827$
- $k^{(2)}(h_1, h_3) = \exp\left(-0.5 \times |0.5 - 2.8|^2\right) = \exp(-2.645) = 0.0710$
- $k^{(2)}(h_2, h_3) = \exp\left(-0.5 \times |1.2 - 2.8|^2\right) = \exp(-1.280) = 0.2780$

Matriks kovariansi Lapisan 2 dan bobot dual $\boldsymbol{\alpha}^{(2)}$:

$$K_y^{(2)} = \begin{bmatrix}1.0100 & 0.7827 & 0.0710\\0.7827 & 1.0100 & 0.2780\\0.0710 & 0.2780 & 1.0100\end{bmatrix}, \quad \boldsymbol{\alpha}^{(2)} = (K_y^{(2)})^{-1}\mathbf{y} = \begin{bmatrix}\mathbf{4.3212}\\\mathbf{-3.3462}\\\mathbf{3.5877}\end{bmatrix} \tag{7}$$

3.3 Langkah 3: Evaluasi Titik Interpolasi Baru ($x_* = 3.0$)

A. Propagasi Maju Lapisan 1 ($x_* \to h_*$): Vektor kemiripan titik uji ke masukan latih: $\mathbf{k}_*^{(1)} = [0.1353,\ 0.6065,\ 0.6065]^T$.

$$\mu_{h*} = \mathbf{k}_*^{(1)T}\boldsymbol{\alpha}^{(1)} = (0.1353 \times -0.0530) + (0.6065 \times 0.8639) + (0.6065 \times 2.6571) = \mathbf{2.1284} \tag{8}$$

$$\sigma_{h*}^2 = 1.0000 - \mathbf{k}_*^{(1)T}(K_y^{(1)})^{-1}\mathbf{k}_*^{(1)} = 1.0000 - 0.6998 = \mathbf{0.3002} \implies \sigma_{h*} = \mathbf{0.5479} \tag{9}$$

Luaran Lapisan 1 adalah distribusi: $h_* \sim \mathcal{N}(2.1284,\ 0.3002)$.

B. Reparameterization Sampling: Ditarik 3 sampel representatif $h_*^{(s)} = \mu_{h*} + \sigma_{h*}\epsilon^{(s)}$:

- **Sampel 1** ($\epsilon^{(1)} = 0$): $h_*^{(1)} = 2.1284$ (Nilai mean)
- **Sampel 2** ($\epsilon^{(2)} = +1$): $h_*^{(2)} = 2.1284 + 0.5479 = \mathbf{2.6763}$ (Mendekati $h_3 = 2.8$)
- **Sampel 3** ($\epsilon^{(3)} = -1$): $h_*^{(3)} = 2.1284 - 0.5479 = \mathbf{1.5805}$ (Mendekati $h_2 = 1.2$)

C. Propagasi Maju Lapisan 2 untuk Masing-masing Sampel ($h_*^{(s)} \to y_*^{(s)}$):

1. **Sampel 1** ($h_*^{(1)} = 2.1284$):
   $\mathbf{k}_*^{(2)(1)} = [0.2656,\ 0.6499,\ 0.7981]^T$
   $\mu_{y*}^{(1)} = \mathbf{k}_*^{(2)(1)T}\boldsymbol{\alpha}^{(2)} = \mathbf{1.8363}, \quad \sigma_{y*}^{2(1)} = 1.0 - \mathbf{k}_*^{(2)(1)T}(K_y^{(2)})^{-1}\mathbf{k}_*^{(2)(1)} = \mathbf{0.1180}$

2. **Sampel 2** ($h_*^{(2)} = 2.6763$):
   $\mathbf{k}_*^{(2)(2)} = [0.0936,\ 0.3363,\ \mathbf{0.9924}]^T$ (sangat mirip dengan $h_3 = 2.8$)
   $\mu_{y*}^{(2)} = \mathbf{2.8397}$ (naik mendekati target $y_3 = 3.0$), $\quad \sigma_{y*}^{2(2)} = \mathbf{0.0186}$ (variansi sangat kecil).

3. **Sampel 3** ($h_*^{(3)} = 1.5805$):
   $\mathbf{k}_*^{(2)(3)} = [0.5578,\ \mathbf{0.9302},\ 0.4754]^T$ (sangat mirip dengan $h_2 = 1.2$)
   $\mu_{y*}^{(3)} = \mathbf{1.0034}$ (turun mendekati target $y_2 = 1.0$), $\quad \sigma_{y*}^{2(3)} = \mathbf{0.0481}$.

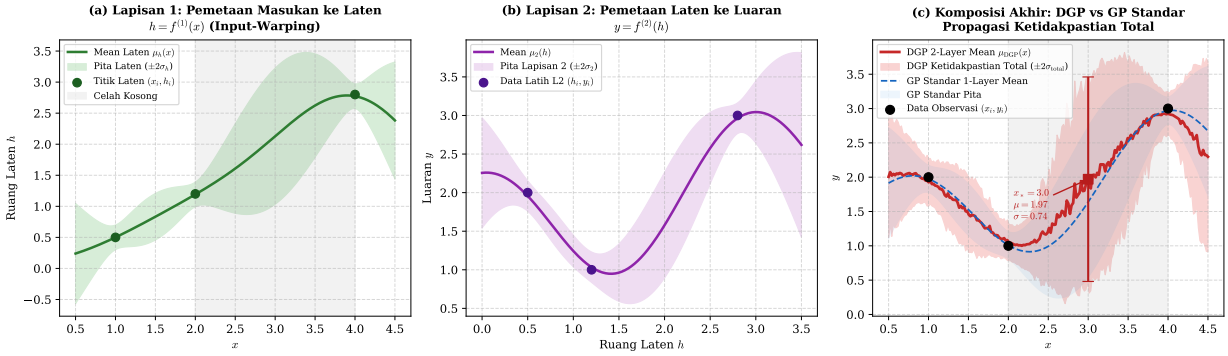
D. Agregasi Luaran via Hukum Variansi Total:

$$\mu_{\text{final}} = \frac{1}{3}\left(1.8363 + 2.8397 + 1.0034\right) = \mathbf{1.8931} \tag{10}$$

$$\mathbb{E}[\sigma_y^2] = \frac{0.1180 + 0.0186 + 0.0481}{3} = \mathbf{0.0616} \quad \text{(Ketidakpastian lokal L2)} \tag{11}$$

$$\text{Var}(\mu_y) = \frac{1}{3}\sum_{s=1}^{3}(\mu_{y*}^{(s)} - \mu_{\text{final}})^2 = \mathbf{0.5636} \quad \text{(Perambatan dari ketidakpastian laten L1)} \tag{12}$$

$$\sigma_{\text{total}}^2 = 0.0616 + 0.5636 = \mathbf{0.6252} \implies \sigma_{\text{total}} = \sqrt{0.6252} = \mathbf{0.7907} \tag{13}$$



Gambar 3: Visualisasi numerik DGP 2-Lapisan: (a) Pemetaan $x \to h$ (*input-warping*), (b) Pemetaan laten ke luaran $h \to y$, dan (c) Kurva akhir DGP dengan penggelembungan pita variansi di wilayah celah data kosong ($x_* = 3.0$).

4 Perbandingan dengan GP Standar dan Relevansi Tugas Akhir

Tabel 1: Perbandingan Metrik Prediksi pada Titik Interpolasi Celah ($x_* = 3.0$).

Parameter Evaluasi	**GP Standar (1-Lapis)**	**DGP (2-Lapis)**	**Makna Fisis & Teoretis**
Prediksi Mean (μ_*)	1.6388	**1.8931**	Mengakomodasi distorsi spasial non-stasioner
Variansi Lokal Luaran	0.3002	0.0616	Ketidakpastian kondisional Lapisan 2
Variansi Merambat (L_1)	0	**0.5636**	Fluktuasi fitur laten merambat ke luaran
Variansi Total (σ_*^2)	0.3002	**0.6252**	Menggelembung 2x lipat (lebih realistis)
Standar Deviasi (σ_*)	0.5479	**0.7907**	Estimasi ketidakpastian berjenjang yang jujur

Relevansi untuk Tugas Akhir (*Image Segmentation with DGP*):
Pada segmentasi citra, ketidakpastian laten sangat penting pada piksel batas kontur (*boundary edges*) antar kelas objek. DGP mampu mempertahankan ketidakpastian representasi spasial di *hidden layer*, sehingga menghasilkan estimasi batas segmen yang terkalibrasi secara probabilistik tanpa menderita *overconfidence*.