BIMBINGAN TUGAS AKHIR #6

Rabu, 21 Oktober 2026

1 Pembuktian Distribusi Normal $y = f(x) + \varepsilon$

Diberikan model observasi linier:

$$y = f(x) + \varepsilon = wx + \varepsilon \tag{1}$$

dengan galat $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$.

MGF Distribusi Normal:

- **Univariat**: Untuk peubah acak $Z \sim \mathcal{N}(\mu, \sigma^2)$, MGF didefinisikan sebagai:

$$M_Z(t) = \mathbb{E}\left[e^{tZ}\right] = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right) \tag{2}$$

- **Multivariat**: Untuk vektor acak $\mathbf{Z} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ dengan $\mathbf{Z} \in \mathbb{R}^k$, MGF didefinisikan sebagai:

$$M_{\mathbf{Z}}(\mathbf{t}) = \mathbb{E}\left[\exp(\mathbf{t}^T\mathbf{Z})\right] = \exp\left(\mathbf{t}^T\boldsymbol{\mu} + \frac{1}{2}\mathbf{t}^T\Sigma\mathbf{t}\right) \tag{3}$$

Untuk galat $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$, MGF-nya adalah $M_\varepsilon(t) = \exp\left(\frac{1}{2}\sigma_n^2 t^2\right)$.

Pembuktian distribusi observasi ditinjau dalam dua kasus nilai bobot:

1. **Kasus 1**: Bobot bernilai konstan ($w \in \mathbb{R}$ atau $\mathbf{w} \in \mathbb{R}^d$).
2. **Kasus 2**: Bobot berdistribusi normal ($w \sim \mathcal{N}(0, \sigma_w^2)$ atau $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \Sigma_p)$).

1.1 Kasus 1: Bobot Bernilai Konstan

Claim 1.1 (Bentuk Skalar Univariat)**.** *Jika $w \in \mathbb{R}$ berupa skalar konstan dan galat $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$, maka variabel observasi $y = wx + \varepsilon$ berdistribusi normal:*

$$y \sim \mathcal{N}\left(wx,\ \sigma_n^2\right) \tag{4}$$

Proof. MGF dari y:

$$\begin{aligned}
M_y(t) &= \mathbb{E}\left[e^{t(wx+\varepsilon)}\right] \\
&= \mathbb{E}\left[e^{twx}e^{t\varepsilon}\right] \\
&= e^{twx}\,\mathbb{E}\left[e^{t\varepsilon}\right] \\
&= e^{twx}M_\varepsilon(t) \\
&= e^{twx}\exp\left(\frac{1}{2}\sigma_n^2 t^2\right) \\
&= \exp\left((wx)t + \frac{1}{2}\sigma_n^2 t^2\right)
\end{aligned} \tag{5}$$

Berdasarkan bentuk MGF normal univariat pada Persamaan (2) dengan $\mu = wx$ dan $\sigma^2 = \sigma_n^2$, terbukti bahwa:

$$y \sim \mathcal{N}\left(wx,\ \sigma_n^2\right) \tag{6}$$

□

Claim 1.2 (Bentuk Vektor Multivariat: Persamaan (2.3) GPML)**.** *Untuk sekumpulan input* $X = [\mathbf{x}_1, \ldots, \mathbf{x}_n] \in \mathbb{R}^{d \times n}$*, bobot* $\mathbf{w} \in \mathbb{R}^d$ *bernilai konstan, dan galat* $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma_n^2 I_n)$ *(Rasmussen & Williams, 2006, hlm. 9), distribusi bersyarat observasi* $\mathbf{y}$ *berdistribusi normal multivariat:*

$$\mathbf{y} \mid X, \mathbf{w} \sim \mathcal{N}\left(X^T\mathbf{w},\ \sigma_n^2 I_n\right) \tag{7}$$

dengan fungsi kepadatan probabilitas (likelihood) yang terfaktorisasi:

$$p(\mathbf{y} \mid X, \mathbf{w}) = \prod_{i=1}^{n} p(y_i \mid \mathbf{x}_i, \mathbf{w}) = \frac{1}{(2\pi\sigma_n^2)^{n/2}} \exp\left(-\frac{1}{2\sigma_n^2}|\mathbf{y} - X^T\mathbf{w}|^2\right) \tag{8}$$

Proof. MGF bersyarat dari $\mathbf{y} \mid X, \mathbf{w}$ didefinisikan sebagai:

$$\begin{aligned} M_{\mathbf{y}|X,\mathbf{w}}(\mathbf{t}) &= \mathbb{E}\left[\exp\left(\mathbf{t}^T(X^T\mathbf{w} + \boldsymbol{\varepsilon})\right) \mid X, \mathbf{w}\right] \\ &= \exp\left(\mathbf{t}^T(X^T\mathbf{w})\right) \cdot \mathbb{E}\left[\exp\left(\mathbf{t}^T\boldsymbol{\varepsilon}\right)\right] \\ &= \exp\left(\mathbf{t}^T(X^T\mathbf{w})\right) \cdot M_{\boldsymbol{\varepsilon}}(\mathbf{t}) \\ &= \exp\left(\mathbf{t}^T(X^T\mathbf{w}) + \frac{1}{2}\mathbf{t}^T\left(\sigma_n^2 I_n\right)\mathbf{t}\right) \end{aligned} \tag{9}$$

Berdasarkan MGF normal multivariat pada Persamaan (3) dengan $\boldsymbol{\mu} = X^T\mathbf{w}$ dan $\Sigma = \sigma_n^2 I_n$, terbukti bahwa $\mathbf{y} \mid X, \mathbf{w} \sim \mathcal{N}\left(X^T\mathbf{w},\ \sigma_n^2 I_n\right)$.

Karena $\Sigma = \sigma_n^2 I_n$ diagonal, suku eksponen pada MGF (9) dapat diuraikan:

$$M_{\mathbf{y}|X,\mathbf{w}}(\mathbf{t}) = \prod_{i=1}^{n} \exp\left(t_i(\mathbf{x}_i^T\mathbf{w}) + \frac{1}{2}\sigma_n^2 t_i^2\right) = \prod_{i=1}^{n} M_{y_i|\mathbf{x}_i,\mathbf{w}}(t_i) \tag{10}$$

Karena MGF gabungan bersyarat sama dengan hasil kali MGF masing-masing variabel, maka setiap $y_1, \ldots, y_n$ saling bebas dengan $y_i \mid \mathbf{x}_i, \mathbf{w} \sim \mathcal{N}(\mathbf{x}_i^T\mathbf{w}, \sigma_n^2)$. Oleh karena itu, fungsi kepadatan bersama terfaktorisasi menjadi:

$$p(\mathbf{y} \mid X, \mathbf{w}) = \prod_{i=1}^{n} p(y_i \mid \mathbf{x}_i, \mathbf{w}) = \frac{1}{(2\pi\sigma_n^2)^{n/2}} \exp\left(-\frac{1}{2\sigma_n^2}|\mathbf{y} - X^T\mathbf{w}|^2\right) \tag{11}$$

□

1.2 Kasus 2: Bobot w Berdistribusi Normal ($w \sim \mathcal{N}(0, \sigma_w^2)$)

Diberikan $w \sim \mathcal{N}(0, \sigma_w^2)$ dan diasumsikan w dan ε saling bebas.

Claim 1.3. *Fungsi* $f(x) = wx$ *berdistribusi normal:*

$$f(x) \sim \mathcal{N}\left(0,\ x^2\sigma_w^2\right) \tag{12}$$

Proof. MGF dari w adalah $M_w(t) = \exp\left(\frac{1}{2}\sigma_w^2 t^2\right)$. MGF dari $f(x) = wx$:

$$\begin{aligned} M_{f(x)}(t) &= \mathbb{E}_w\left[e^{t(wx)}\right] = \mathbb{E}_w\left[e^{(tx)w}\right] = M_w(tx) \\ &= \exp\left(\frac{1}{2}\sigma_w^2(tx)^2\right) \\ &= \exp\left(\frac{1}{2}t^2\left(x^2\sigma_w^2\right)\right) \end{aligned} \tag{13}$$

Sesuai bentuk MGF normal univariat pada Persamaan (2) dengan $\mu = 0$ dan variansi $\sigma^2 = x^2\sigma_w^2$, terbukti bahwa:

$$f(x) \sim \mathcal{N}\left(0,\ x^2\sigma_w^2\right) \tag{14}$$

□

Claim 1.4. *Variabel observasi $y = f(x) + \varepsilon$ berdistribusi normal:*

$$y \sim \mathcal{N}\left(0,\ x^2\sigma_w^2 + \sigma_n^2\right) \tag{15}$$

Proof. Karena w dan ε saling bebas, maka $f(x)$ dan ε saling bebas. MGF dari $y = f(x) + \varepsilon$:

$$\begin{aligned} M_y(t) &= \mathbb{E}_{w,\varepsilon}\left[e^{t(f(x)+\varepsilon)}\right] \\ &= \mathbb{E}\left[e^{tf(x)}\right] \cdot \mathbb{E}\left[e^{t\varepsilon}\right] \\ &= M_{f(x)}(t) \cdot M_\varepsilon(t) \\ &= \exp\left(\frac{1}{2}t^2\left(x^2\sigma_w^2\right)\right) \cdot \exp\left(\frac{1}{2}\sigma_n^2 t^2\right) \\ &= \exp\left(\frac{1}{2}t^2\left(x^2\sigma_w^2 + \sigma_n^2\right)\right) \end{aligned} \tag{16}$$

Sesuai bentuk MGF normal univariat pada Persamaan (2) dengan $\mu = 0$ dan variansi $\sigma^2 = x^2\sigma_w^2 + \sigma_n^2$, terbukti bahwa:

$$y \sim \mathcal{N}\left(0,\ x^2\sigma_w^2 + \sigma_n^2\right) \tag{17}$$

□

Claim 1.5 (Bentuk Vektor Multivariat)**.** *Untuk sekumpulan input $X = [\mathbf{x}_1, \ldots, \mathbf{x}_n]^T \in \mathbb{R}^{n\times d}$, bobot $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \Sigma_p)$, dan galat $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma_n^2 I_n)$ dengan $\mathbf{w}$ dan $\boldsymbol{\varepsilon}$ saling bebas:*

$$\mathbf{f} \sim \mathcal{N}\left(\mathbf{0},\ X\Sigma_p X^T\right) \quad \textit{dan} \quad \mathbf{y} \sim \mathcal{N}\left(\mathbf{0},\ X\Sigma_p X^T + \sigma_n^2 I_n\right) \tag{18}$$

Proof. Berdasarkan MGF normal multivariat pada Persamaan (3):

$$M_{\mathbf{f}}(\mathbf{t}) = \mathbb{E}\left[\exp(\mathbf{t}^T X\mathbf{w})\right] = \exp\left(\frac{1}{2}\mathbf{t}^T\left(X\Sigma_p X^T\right)\mathbf{t}\right) \implies \mathbf{f} \sim \mathcal{N}\left(\mathbf{0},\ X\Sigma_p X^T\right) \tag{19}$$

Karena $\mathbf{w}$ dan $\boldsymbol{\varepsilon}$ saling bebas:

$$\begin{aligned} M_{\mathbf{y}}(\mathbf{t}) &= M_{\mathbf{f}}(\mathbf{t}) \cdot M_{\boldsymbol{\varepsilon}}(\mathbf{t}) \\ &= \exp\left(\frac{1}{2}\mathbf{t}^T\left(X\Sigma_p X^T + \sigma_n^2 I_n\right)\mathbf{t}\right) \implies \mathbf{y} \sim \mathcal{N}\left(\mathbf{0},\ X\Sigma_p X^T + \sigma_n^2 I_n\right) \end{aligned}$$

□

2 Konsep Deep Neural Network (DNN) dan Transisi Menuju Deep Gaussian Process (DGP)

2.1 Formulasi Aljabar Linier Arsitektur Deep Neural Network (DNN)

Diberikan vektor masukan $\mathbf{x} \in \mathbb{R}^{d_0}$. Jaringan saraf tiruan mendalam (*Deep Neural Network* / DNN) dengan L lapisan tersembunyi (*hidden layers*) memetakan masukan $\mathbf{x}$ menuju estimasi keluaran $\hat{\mathbf{y}} \in \mathbb{R}^{d_{L+1}}$ melalui komposisi berulang dari pemetaan linier berbobot dan fungsi aktivasi non-linier.

Untuk setiap lapisan $\ell \in \{1, 2, \ldots, L\}$:

$$\mathbf{z}^{(\ell)} = W^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)} \tag{20}$$

$$\mathbf{h}^{(\ell)} = \sigma\left(\mathbf{z}^{(\ell)}\right) \tag{21}$$

dengan keselarasan dimensi operasi aljabar linier didefinisikan secara presisi sebagai berikut:

- $\mathbf{h}^{(0)} = \mathbf{x} \in \mathbb{R}^{d_0}$ adalah representasi awal pada lapisan masukan (*input layer*).

- $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ adalah matriks bobot pada lapisan ke-ℓ, di mana indeks baris menyatakan jumlah neuron pada lapisan saat ini (d_ℓ) dan indeks kolom menyatakan dimensi fitur dari lapisan sebelumnya ($d_{\ell-1}$).
- $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_\ell}$ adalah vektor bias pada lapisan ke-ℓ.
- $\mathbf{z}^{(\ell)} \in \mathbb{R}^{d_\ell}$ adalah vektor aktivasi pra-nonlinier (*pre-activation*).
- $\sigma(\cdot) : \mathbb{R} \to \mathbb{R}$ adalah fungsi aktivasi non-linier (seperti ReLU, Sigmoid, atau GELU) yang diaplikasikan secara elemen-demi-elemen (*element-wise*).
- $\mathbf{h}^{(\ell)} \in \mathbb{R}^{d_\ell}$ adalah vektor representasi fitur tersembunyi (*hidden representation*) pada lapisan ke-ℓ.

Pada lapisan keluaran akhir ($\ell = L + 1$):

$$\hat{\mathbf{y}} = \mathbf{h}^{(L+1)} = W^{(L+1)}\mathbf{h}^{(L)} + \mathbf{b}^{(L+1)} \tag{22}$$

dengan $W^{(L+1)} \in \mathbb{R}^{d_{L+1} \times d_L}$ dan $\mathbf{b}^{(L+1)} \in \mathbb{R}^{d_{L+1}}$. Secara keseluruhan, model DNN mengekspresikan fungsi komposit hierarkis:

$$\hat{\mathbf{y}} = \left(f_{L+1} \circ f_L \circ \cdots \circ f_1\right)(\mathbf{x}) \tag{23}$$

2.2 Keterbatasan Gaussian Process Standar vs Keunggulan Komposisi Hierarkis

Model *Gaussian Process* (GP) standar pada Seksi 1 memodelkan sebaran atas fungsi non-parametrik melalui fungsi rata-rata $m(\mathbf{x})$ dan fungsi kernel kovariansi $k(\mathbf{x}, \mathbf{x}')$:

$$f(\mathbf{x}) \sim \mathcal{GP}\left(m(\mathbf{x}),\ k(\mathbf{x}, \mathbf{x}')\right), \quad y = f(\mathbf{x}) + \varepsilon \tag{24}$$

Meskipun GP memiliki keunggulan utama dalam memberikan kuantifikasi ketidakpastian yang terukur secara analitik, GP standar memiliki karakteristik arsitektur "dangkal" (*shallow architecture*):

1. **Transformasi Fitur Tunggal**: Hubungan masukan-keluaran ditentukan langsung oleh satu fungsi kernel $k(\mathbf{x}, \mathbf{x}')$. Hal ini membatasi kemampuan GP standar dalam memodelkan fungsi yang sangat non-stasioner, memiliki variasi skala spasial yang drastis (*varying lengthscales*), atau memiliki diskontinuitas lokal.
2. **Ketiadaan Pembelajaran Representasi Bertingkat**: GP standar tidak mengekstraksi fitur representasi secara bertingkat (*hierarchical representation learning*) dari data masukan berdimensi tinggi, seperti susunan piksel mentah pada data citra.

Sebaliknya, keunggulan mendasar dari DNN terletak pada arsitektur komposit bertingkat pada Persamaan (23), di mana setiap lapisan mempelajari abstraksi fitur yang semakin tinggi secara otomatis dari representasi lapisan sebelumnya.

2.3 Transisi Menuju Deep Gaussian Process (DGP)

Keterkaitan konseptual antara jaringan saraf tiruan dan Gaussian Process diawali oleh Teorema Neal (1995): jaringan saraf tiruan satu lapis dengan lebar neuron menuju tak terhingga ($d_1 \to \infty$) yang parameter bobotnya berdistribusi independen identik berkonvergen secara eksak menuju Gaussian Process (*Neural Network Gaussian Process* / NNGP).

Berdasarkan fondasi ini, Damianou & Lawrence (2013) memperluas konsep komposisi hierarkis pada DNN ke dalam model Gaussian Process, menghasilkan arsitektur **Deep Gaussian Process**

(DGP). Pada DGP, setiap transformasi parametrik tetap $\mathbf{h}^{(\ell)} = \sigma(W^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)})$ pada DNN digantikan oleh pemetaan fungsi acak Gaussian Process:

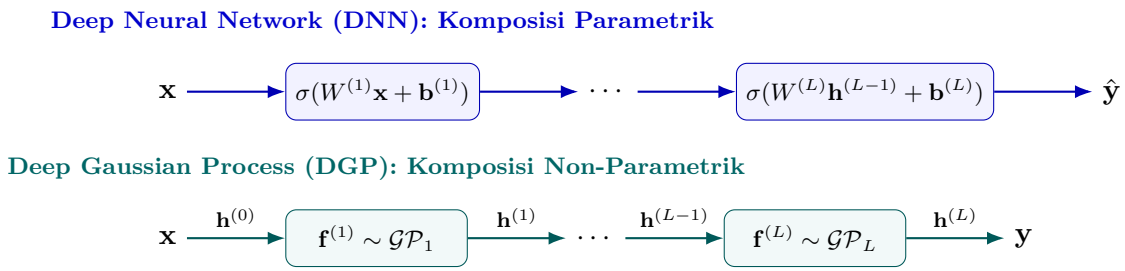
$$\mathbf{f}^{(\ell)} \sim \mathcal{GP}\left(\mathbf{0},\ K^{(\ell)}(\mathbf{h}^{(\ell-1)}, \mathbf{h}^{(\ell-1)})\right) \tag{25}$$

$$\mathbf{h}^{(\ell)} = \mathbf{f}^{(\ell)}(\mathbf{h}^{(\ell-1)}) + \boldsymbol{\varepsilon}^{(\ell)}, \quad \boldsymbol{\varepsilon}^{(\ell)} \sim \mathcal{N}\left(\mathbf{0},\ \sigma_\ell^2 I\right) \tag{26}$$

dengan masukan awal $\mathbf{h}^{(0)} = \mathbf{x}$ dan keluaran akhir observasi $\mathbf{y} = \mathbf{h}^{(L)} + \boldsymbol{\varepsilon}$.

Struktur pemetaan DGP merupakan komposisi bertingkat dari fungsi-fungsi acak Gaussian:

$$\mathbf{y} = \mathbf{f}^{(L)}\left(\mathbf{f}^{(L-1)}\left(\ldots \mathbf{f}^{(1)}(\mathbf{x}) \ldots\right)\right) + \boldsymbol{\varepsilon} \tag{27}$$



Gambar 1: Transisi arsitektur dari komposisi parametrik (DNN) menuju komposisi hierarkis fungsi acak (DGP).

Tabel 1: Perbandingan Karakteristik Arsitektur DNN, GP Standar, dan DGP.

Karakteristik	**Deep Neural Network**	**Gaussian Process Standar**	**Deep Gaussian Process**
Struktur Pemetaan	Komposisi bertingkat (L lapis)	Tunggal / dangkal (1 lapis)	Komposisi bertingkat (L lapis)
Sifat Transformasi	Parametrik berbobot tetap	Non-parametrik via Kernel tunggal	Non-parametrik via GP hierarkis
Representasi Fitur	Hierarki fitur mendalam	Terbatas pada ruang fitur kernel	Hierarki kernel mendalam
Kuantifikasi Ketidakpastian	Tidak tersedia (titik pasti $\hat{\mathbf{y}}$)	Analitik pada seluruh ruang masukan	Inheren di setiap lapisan
Fleksibilitas Non-Stasioner	Sangat fleksibel (via aktivasi)	Terbatas asumsi stasioneritas kernel	Sangat fleksibel (*input-warping*)

Dengan demikian, arsitektur DGP menjadi jembatan ideal bagi topik segmentasi citra: ia mewarisi kemampuan representasi hierarkis DNN untuk mengekstrak fitur spasial kompleks dari data citra, sekaligus mempertahankan kepastian estimasi ketidakpastian berbasis prinsip distribusi Gaussian.